

InceptionV3 기반의 심장비대증 분류 정확도 향상 연구

정우연¹ · 김정훈^{2*}

¹경북대학교대학원 의용생체공학과

²경북대학교병원 생명의학연구원

A Study on the Improvement of Accuracy of Cardiomegaly Classification Based on InceptionV3

Woo Yeon Jeong¹ and Jung Hun Kim^{2*}

¹Department of Biomedical Engineering Kyungpook National University

²Bio-Medical Research institute, Kyungpook National University Hospital

(Manuscript received 19 August 2021 ; revised 6 February 2022 ; accepted 17 February 2022)

Abstract: The purpose of this study is to improve the classification accuracy compared to the existing InceptionV3 model by proposing a new model modified with the fully connected hierarchical structure of InceptionV3, which showed excellent performance in medical image classification. The data used for model training were trained after data augmentation on a total of 1026 chest X-ray images of patients diagnosed with normal heart and Cardiomegaly at Kyungpook National University Hospital. As a result of the experiment, the learning classification accuracy and loss of the InceptionV3 model were 99.57% and 1.42, and the accuracy and loss of the proposed model were 99.81% and 0.92. As a result of the classification performance evaluation for precision, recall, and F1 score of Inception V3, the precision of the normal heart was 78%, the recall rate was 100%, and the F1 score was 88. The classification accuracy for Cardiomegaly was 100%, the recall rate was 78%, and the F1 score was 88. On the other hand, in the case of the proposed model, the accuracy for a normal heart was 100%, the recall rate was 92%, and the F1 score was 96. The classification accuracy for Cardiomegaly was 95%, the recall rate was 100%, and the F1 score was 97. If the chest X-ray image for normal heart and Cardiomegaly can be classified using the model proposed based on the study results, better classification will be possible and the reliability of classification performance will gradually increase.

Key words: Artificial intelligence, Deep learning, Classification, Inception, Cardiomegaly

1. 서 론

심장비대증(Cardiomegaly)은 심장 내부 공간의 확장이나 심실비대에 의해 심장이 커진 상태를 의미하며 초음파나 흉부 X-ray 영상의 판독으로 진단할 수 있다[1]. 그러나 의료 영상 판독 시 전문의의 숙련된 기술이나 영상의 질에 따라 진단 결과가 달라질 수도 있으며[2,3], 조기에 발견되지 못

하면 심각한 합병증을 초래할 수 있다[4,5].

기술의 발전으로 최근에는 인공지능을 이용한 딥러닝을 의료에 접목시키는 연구들이 많이 진행되고 있다[6]. 그 중에는 주로 영상의학 분야에 딥러닝 알고리즘을 이용한 이미지 분류 연구들도 많이 진행되고 있다[7,8]. 현재 이미지 분류를 이용한 딥러닝 알고리즘에는 VGGNet, ResNet, GoogLeNet(Inception) 등 우수한 분류 성능 결과를 보여준 다양한 알고리즘이 있으며 지속적으로 새로운 알고리즘이 개발되어지고 있다[9].

GoogLeNet(Inception) 알고리즘은 이미지 분류 대회에서 우수한 분류 성능으로 우승하였다. GoogLeNet(Inception) 알고리즘 구조를 지속적으로 개선하여 InceptionV3 모델을 개발하였고, 의료 영상을 이용한 이미지 분류에서도 우수한

*Corresponding Author : Jung Hun Kim
Bio-Medical Research institute, Kyungpook National University Hospital, 135, Dongdeok-ro, Jung-gu, Daegu, Republic of Korea
Tel: +82-53-950-7956
E-mail: fainal2@naver.com

결과를 보여주었다[10,11]. 딥러닝 알고리즘에 의료 영상을 이용한 분류 연구에서는 CT, MRI, X-ray 영상과 같은 여러가지 의료 영상이 사용되고 있고 그 중 X-ray 영상을 이용한 연구가 활발하게 진행되어지고 있다[12,13]. X-ray 영상에 대한 연구 중에서 InceptionV3 알고리즘을 이용하여 온라인 상에서 제공되어지는 흉부 X-ray 영상의 폐 질환에 대한 분류 연구에서는 우수한 결과를 보였다[10]. 최근에는 InceptionV3의 단점을 보완한 InceptionV4모델이나 Inception-ResNet과 같이 새로운 모델들이 등장하고 있으나 InceptionV3의 기본구조를 이용하여 의료영상에 대한 분류 정확도를 향상시키는 연구는 없다.

본 연구에서는 VGGNet과 ResNet 등의 다양한 딥러닝 분류 네트워크 모델이 있지만 흉부 X-ray 영상을 이용하여 폐 질환 분류에서 우수한 성능이 입증된 Inception V3 모델을 이용하여 InceptionV3 딥러닝 알고리즘의 기본 구조에서 완전연결계층(Fully Connected Layer)을 통해 정상 심장과 심장비대증 이미지 분류에 대한 모델의 분류 정확도를 향상시키는 방법을 제안하였다.

II. 연구 방법

1. 개발 및 구현 환경

표 1은 연구에 사용된 개발환경을 나타내며 연구 진행을 위하여 CPU : Intel (R) Core (TM) i7-8700k CPU@3.70GHZ, RAM : 32.0GB, GPU : NVIDIA GeForce GTX 1080Ti를

표 1. 연구에 사용된 개발환경

Table 1. Development environment used for research

Components	Specification
CPU	Intel (R) Core (TM) i7-8700k
Speed	3.70 GHz
RAM	32.0 GB
GPU	NVIDIA Geforce GTX1080 Ti
OS	Windows 10

표 2. 딥러닝 모델 구현환경

Table 2. Deep learning model implementation environment

Components	Version
Python	3.8.5
Keras	2.4.3
Anaconda	2020.11
Jupyter notebook	6.1.4
Tensorflow	2.4.1
Numpy	1.19.2
Matplotlib	3.3.2

사용하였다. 표 2는 알고리즘 구현환경 조건을 나타내며 딥러닝 알고리즘 구현 환경으로 파이썬(Python) 언어를 사용하여 아나콘다(Anaconda) 환경의 주피터 노트북(Jupyter notebook)을 이용하였고 Python 3.8.5, Tensorflow 2.4.1, Keras 2.4.3, Jupyter notebook 6.1.4, Numpy 1.19.2, Matplotlib 3.3.2을 사용하였다.

2. 데이터 수집

사용된 흉부 X-ray 데이터의 경우 경북대학교병원 내 X-ray 장비를 이용하여 촬영되어진 영상이며 경북대학교병원의 영상의학과 전문의로부터 소견받은 심장비대증 데이터와 정상심장 데이터이다. 데이터는 경북대학교병원의 임상 시험 심사 위원회(Institutional review board, IRB)의 승인을 받은 후 경북대학교병원 내 PACS 시스템(Picture archiving communication system, PACS)을 사용하여 데이터를 수집하였으며 20세 이상 95세 미만의 환자들을 대상으로 2010년 1월부터 2020년 12월까지 정상 심장 및 심장비대증 진단을 받은 환자의 흉부 X-ray 영상 1026건을 수집하였다(KNUH 2020-08-017).

3. 딥러닝 알고리즘 모델

본 연구에서는 기존 InceptionV3 딥러닝 알고리즘과 제안하는 수정된 알고리즘을 이용하여 의료 영상 분류에 대한 성능을 비교하였다.

(1) InceptionV3

InceptionV3는 2014년 ILSVRC 대회에서 1등을 차지한 모델 GoogLeNet을 응용한 버전으로 총 48개의 계층으로 구성된 합성곱 신경망(CNN, Convolutional neural network)이며 여러 엄격한 제약 조건에서도 잘 수행될 수 있는 구조로 그림 1의 a)와 같이 설계되어 있다[14]. InceptionV3는 노드 간의 연결을 줄이며, Dense 연산을 하는 구조로 데이터의 특징을 추출하기 위해 Convolution 연산을 1×1, 3×3, 5×5로 구성하여 연결하였고 Max pooling을 이용하여 연산을 한다. 이때 연산의 양이 많아서 1×1 Convolution 연산을 부분마다 넣어 차원을 감소시킨 뒤 3×3과 5×5 Convolution 연산을 수행함으로써 연산의 양이 줄어들며 효율적인 연산이 가능하다. 이와 같은 구조로 InceptionV3는 연산의 복잡도를 줄여 적은 양의 파라미터를 사용함으로써 학습의 속도를 향상시키는 장점을 가지고 있다[15,16]. 효율적인 연산을 바탕으로 InceptionV3의 마지막 출력층에서 다중 분류에 사용되는 softmax 함수를 통해 정상 심장과 심장비대증의 분류 결과 값이 출력된다.

(2) 제안된 InceptionV3

본 연구에서 제안된 InceptionV3 모델은 정상 심장과 심




그림 1. 기존 InceptionV3의 구조와 제안된 InceptionV3의 구조

Fig. 1. The structure of the original InceptionV3 and the structure of the proposed InceptionV3

장비대증을 구분하는 알고리즘으로 구성되었다. 제안하는 InceptionV3의 구조는 기존의 InceptionV3의 Convolution 연산의 구조는 유지하되 그림 1의 b)와 같이 Keras 기반의 InceptionV3의 완전연결계층(Fully connected layer)의 구조를 수정한 신경망이며 파라미터의 수를 줄이기 위하여 global average pooling과 flatten을 거친 후 기울기 소실을 방지하기 위해 활성화 함수로 relu 함수를 적용하여 입력 뉴런의 수가 769 인 하나의 입력층을 시작으로, 신경망의 과적합(overfitting)을 방지하고 성능 향상을 위해 드롭아웃(drop out)의 비율을 0.5로 설정하여[17] 정상 심장과 심장비대증을 분류하기 위해 이진 분류에 적합한 sigmoid 함수를 사용하는 마지막 출력층 으로부터 결과 값이 출력된다.

4. 데이터 세트

본 연구에서 사용된 데이터 세트는 8bit의 JPEG(Joint photograph experts group, JPEG) 파일 형식으로 직접 수집한 정상 심장과 심장비대증 흉부 X-ray 이미지 각각 526 개와 500개를 사용하였다. 표 3은 연구에서 사용된 데이터 세트를 나타낸다. 정상 심장 흉부 X-ray 이미지 526개의 경우 학습 데이터셋, 검증 데이터셋, 테스트 데이터셋으로 분류하여 사용하였다. 학습 데이터 셋 226개는 딥러닝 모델을

학습시키기 위해서 사용되며, 검증 데이터는 셋 200개로 학습시킨 딥러닝 모델이 제대로 학습되었는지 확인하기 위해 사용되어지며, 테스트 데이터 셋은 100개로 최종적으로 모델을 평가하기 위해 사용된다. 심장비대증 흉부 X-ray 이미지 500개도 학습 데이터셋, 검증 데이터셋, 테스트 데이터 셋으로 분류하여 사용하였다. 학습 데이터 셋 250개는 딥러닝 모델을 학습시키기 위해서 사용되며, 검증 데이터는 셋 150개로 학습시킨 딥러닝 모델이 제대로 학습되었는지 확인하기 위해 사용되어지며, 테스트 데이터 셋은 100개로 최종적으로 모델을 평가하기 위해 사용된다.

(1) 데이터 Annotation

그림 3은 연구에서 사용되어진 데이터의 annotation 전과 후를 나타내고 있다. 데이터 annotation의 경우 심장비대증을 판별하는 기준에 의거하여 annotation 프로그램(Aview Research, Coreline Soft, Korea)을 사용하여 데이터 annotation을 진행 하였으며 annotation의 기준은 다음과 같다. 심장비대증은 심장이 커진 상태를 의미하며, 단순 흉부 후전위(Chest PA) 영상에서 양쪽(쇄골) Clavicle의 정중선을 기준으로 심장의 최대 횡내경과 흉곽의 최대 횡내경의 비로 도출할 수 있으며, 심흉비가 0.5 이상이면 심장비대증으로 판단할 수 있다[18]. Annotation은 정상 심장 및 심장비대증 영상에서 심장의 크기에 맞게 네모난 ROI(Region of interest, ROI) 박스를 이용하여 심장을 나타내었다.

(2) 데이터 Augmentation

본 연구에서 학습 데이터의 경우 학습 정확도를 높이기 위하여 데이터 증대(augmentation)를 진행하였다. 정상 심

표 3. 사용된 학습, 검증, 테스트 데이터의 구성

Table 3. Compose of images in train, validation, test data

	Normal Heart	Cardiomegaly
Train	226	250
Validation	200	150
Test	100	100




그림 2. AVIEW 프로그램을 이용한 흉부 X-ray 영상에서의 심장 Annotation (A) Annotation 전 데이터 (B) Annotation 후 데이터
Fig. 2. Heart Annotation on Chest X-ray Image Using AVIEW Program




그림 3. InceptionV3와 제안된 InceptionV3의 분류 정확도 및 손실 (A) InceptionV3 (B) 제안된 InceptionV3
Fig. 3. Classification accuracy and loss of InceptionV3 and Proposed InceptionV3 (A) InceptionV3 (B) Proposed InceptionV3

장의 학습 데이터 226개를 증대시켰으며, 증대 방법은 회전(rotation), 줌 범위(zoom range)를 이용하였다. 회전 조건의 경우 이미지 데이터를 기준점인 0°로부터 10°에서 90°까지 무작위로 회전을 주었으며, 줌 범위의 경우 줌 인과 줌 아웃의 범위를 말하며 이미지 원본 기준점인 100%로부터 60%에서 140%까지 이미지의 배율을 무작위로 확대시키거나 이미지의 배율을 무작위로 축소시켜 정상 심장의 학습 데이터를 총 14,527개로 증대시켰다. 심장비대증의 학습 데이터 250개도 회전과 줌 범위를 정상 심장과 동일한 조건으로 총 16,501개로 증대시켰다.

5. 딥러닝 파라미터 설정

딥 러닝 모델의 학습을 위해서는 입력과 출력 영상의 가로

크기와 세로 크기가 같아야하므로 사용되는 정상 심장과 심장비대증 이미지들을 299×299의 해상도 크기를 가지는 영상으로 정규화를 진행하였다. 배치사이즈는 32로 적용하였고 에포크(epoch)는 10에서 100까지의 조건으로 학습을 진행하였을 때 더 이상의 큰 차이점을 보이지 않는 모델의 학습 성능 결과와 소요되는 학습 시간을 고려하여 30으로 적용하였다. 활성화함수는 이진 분류에 적합한 Sigmoid를 사용하였고 최적화 알고리즘은 InceptionV3에 적합한 RMSProp를 사용하여[19] 흉부 X-ray의 정상 심장과 심장비대증 분류를 위한 딥러닝 모델링을 구현하였다.

6. 딥러닝 모델 평가

의료 이미지를 이용하여 인공지능 모델에 적용할 때에는

특히나 정상군과 비정상군에 대한 분별이 확실하여야 하며 실제 임상치의 판독에 도움을 줄 수 있을 정도로 정확한지, 환자에게 도움을 줄 수 있는지가 중요하다[20]. 본 연구에서는 이를 확인하기 위하여 InceptionV3 딥러닝 알고리즘과 제안하는 알고리즘을 이용하여 흉부 X-ray 심장비대증 이미지 분류를 구현하였으며, 구현한 딥러닝 모델링의 학습 에포크 마다 출력되는 결과 딥러닝 모델의 성능평가에 사용하였다. 성능평가에서 TP(True Positive)는 딥러닝 모델이 실제 양성을 양성으로 분류하는 경우를 의미하고, TN(True Negative)는 실제 음성을 음성으로 분류하는 경우를 의미한다. FP(False Positive)는 실제 음성을 양성으로 분류하는 경우를 의미하며, FN(False Negative)는 실제 양성을 음성으로 분류한 결과를 의미한다. 평가하는 항목으로는 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 스코어(F1 Score)를 평가 항목으로 선정하였으며 계산식은 아래의 식 (1)~(4)를 이용하여 계산하였다[21].

$$\text{Accuracy} = \frac{TP+TN}{TP+FP+TN+FN} \times 100 \quad (1)$$

$$\text{Precision} = \frac{TP}{TP+FP} \times 100 \quad (2)$$

$$\text{Recall} = \frac{TP}{TP+FN} \times 100 \quad (3)$$

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

III. 연구 결과

1. InceptionV3의 흉부 X-ray 분류 정확도 및 손실

InceptionV3를 이용하여 데이터 증대를 적용한 흉부 X-ray 이미지의 정상 심장과 심장비대증 분류에 대한 학습의 성능을 평가하여 결과를 아래의 그림 3의 (A)에서 확인할 수 있다. 모델의 학습 결과, 최종 학습 횟수인 에포크가 30일 때 InceptionV3 딥러닝 모델의 경우 정확도와 손실은 각각 99.57%, 1.42의 결과를 보였다.

2. 제안하는 InceptionV3의 흉부 X-ray 분류 정확도 및 손실

제안하는 InceptionV3 모델을 이용하여 데이터 증대를 적용한 흉부 X-ray 이미지의 정상 심장과 심장비대증 분류에 대한 학습의 성능을 평가하여 결과를 아래의 그림 3의 (B)로 확인할 수 있다. 모델의 학습 결과, 최종 학습 횟수인 에포크가 30일 때 제안하는 모델의 경우 정확도와 손실은 각각 99.81%, 0.92의 결과를 보였다.

3. InceptionV3과 제안하는 InceptionV3의 성능 비교

InceptionV3와 제안하는 InceptionV3 모델을 이용하여

표 4. InceptionV3 모델의 정밀도, 재현율, F1 Score 평가 결과
Table 4. Precision, recall, and F1 Score evaluation results of InceptionV3 model

	Precision(%)	Recall(%)	F1 Score(%)
Normal	78	100	88
Cardiomegaly	100	78	88

표 5. 제안하는 InceptionV3 모델의 정밀도, 재현율, F1 Score 평가 결과
Table 5. Precision, recall, and F1 Score evaluation results of the proposed InceptionV3 model

	Precision(%)	Recall(%)	F1 Score(%)
Normal	100	92	96
Cardiomegaly	95	100	97

흉부 X-ray 이미지의 정상 심장과 심장비대증 분류에 대한 정밀도, 재현율, F1 Score 평가를 진행하였으며 아래의 표 4와 표 5는 모델의 분류를 평가한 표이다.

정상 심장에 대하여 InceptionV3 모델의 분류 정밀도는 78%와 재현율이 100%인 결과를 보였고 심장비대증에 대한 분류 정밀도는 100%, 재현율이 78%의 결과를 보였다. 정밀도와 재현율의 조화 평균을 의미하는 F1 Score는 100에 가까울수록 모델의 분류 능력이 우수하다고 평가할 수 있으며 InceptionV3 모델의 경우 정상 심장과 심장비대증에 대한 F1 Score가 100에 가까운 88의 결과로 우수한 결과를 보였다.

반면에 제안하는 InceptionV3 모델의 경우 정상 심장에 대한 정밀도와 재현율의 결과를 바탕으로 F1 Score가 96인 결과를 보였고 심장비대증에 대한 F1 Score 값은 97의 결과를 보여주며 이러한 결과로 기존의 InceptionV3 모델에 비해 제안하는 InceptionV3 모델이 흉부 X-ray 이미지에 대한 특징 추출 및 정상심장과 심장비대증에 대한 분류 성능이 우수하다고 평가하였다.

III. 고찰 및 결론

의료영상 분류에서 우수한 분류 능력을 보여준 InceptionV3 모델로 본 연구에서는 InceptionV3의 기본구조를 바탕으로 Fully Connected Layer의 구조를 수정하여 의료영상을 이용한 이미지 분류의 정확도 향상을 위한 연구를 진행하였다.

제안된 구조를 갖는 InceptionV3모델을 통하여 기존의 InceptionV3와 분류 정확도를 비교한 결과 제안하는 모델의 분류 성능이 조금 더 우수한 평가 결과를 보여주었다. 정확도의 경우 0.24%가 증가하였고 손실은 0.5가 감소한 결과를 보였다. InceptionV3와 제안하는 InceptionV3의 성능 비교 결과를 보면 InceptionV3는 정상 심장 환자를 100%로 잘 찾

아냈지만 그 중 78%를 정상 심장으로 분류하였고 심장비대증 환자는 100%중에 78%만을 심장비대증 환자로 판별하였으나 78%의 환자 모두 심장비대증으로 잘 분류하였다. 제안하는 InceptionV3는 정상 심장 환자 100%중에 92%로 판별하였지만 판별해낸 92%의 정상 심장 환자 모두를 정상 심장으로 분류하였다. 심장비대증 환자의 경우 100%로 잘 찾아냈으며 그 중 95%를 심장비대증 환자로 분류해내어 매우 우수한 분류 성능을 보여주었다. F1 Score는 정밀도와 재현율의 조화에 대한 평균을 의미하며 높은 값일수록 모델의 성능이 좋음을 나타낸다. 본 연구에서 사용된 InceptionV3의 F1 Score는 정상 심장과 심장비대증 모두 88의 결과를 보였고 제안하는 InceptionV3의 F1 Score는 정상 심장은 96, 심장비대증은 97의 결과를 보여 제안하는 InceptionV3의 모델이 조금 더 우수한 분류 성능을 보였다. 추가적으로 학습에 소요되는 시간도 제안하는 모델이 평균적으로 40초정도 빨랐다. 이는 학습되는 파라미터의 개수가 InceptionV3에 비해 제안하는 InceptionV3가 적기 때문에 얻은 결과라고 생각된다. 다만, 에포크가 30일 때 Validation loss가 높은 결과를 보여주었다. 이는 모델의 학습 시 오버피팅이 발생한 것으로 보이며 추후 연구에서는 모델의 학습 데이터를 더 늘이거나 하이퍼파라미터의 수정을 통해 해결할 수 있는 문제로 생각된다.

50

본 연구와 유사한 연구인 Kim, J. Y의 InceptionV3를 이용하여 흉부 X-ray 영상 분류 연구에서 InceptionV3의 뛰어난 분류 성능 결과를 보여주었고[10], 본 연구에서 제안하는 모델은 이와 동등하거나 조금 더 훌륭한 분류 성능 결과를 보였다. 이는 모델의 구조뿐만 아니라 사용되어지는 데이터의 종류 그리고 데이터의 비율 그리고 모델의 하이퍼파라미터 설정이 다른 차이점으로 얻은 결과라고 생각된다.

추후 연구에서는 제안하는 모델을 이용하여 정상 심장과 심장비대증 흉부 X-ray영상에 국한되지 않고 조금 더 다양한 의료영상을 이용한 연구가 필요할 것으로 생각되며 이를 통해 모델의 분류 성능에 대한 신뢰도가 향상될 수 있을 것으로 판단된다. 그리고 해외 유사 연구에서 사용되어지는 8:2 혹은 7:3의 데이터 비율로 연구를 진행해본다면 조금 더 우수한 결과를 얻을 수 있을 것으로 생각된다.

정상 심장과 심장비대증에 대한 흉부 X-ray 영상 분류 시 제안하는 모델을 이용할 경우 보다 우수한 분류 결과를 얻을 수 있다.

References

- [1] Philbin EF, Garg R, Danisa K, Denny DM, Gosselin G, Hassapoyannes C. Digitalis Investigation Group. The relationship between cardiothoracic ratio and left ventricular ejection fraction in congestive heart failure. *Archives of internal medicine*. 1998;158(5):501-506.
- [2] Anderson JC, Baltaxe HA, Wolf GL. Inability to show clot: one limitation of ultrasonography of the abdominal aorta. *Radiology*. 1979;132(3):693-696.
- [3] Moon HJ, Kim EK, Park JS, Kwak JY. Thyroid Ultrasound: Change of Inter-observer Variability and Diagnostic Performance after Training. *Journal of Korean Society of Ultrasound in Medicine*. 2011;30(1):23-28.
- [4] Frohlich ED. Left ventricular hypertrophy as a risk factor. *Cardiology clinics*. 1986;4(1):137-144.
- [5] Levy D, Anderson KM, Savage DD, Kannel WB, Christiansen JC, Castelli WP. Echocardiographically detected left ventricular hypertrophy: prevalence and risk factors: the Framingham Heart Study. *Annals of internal medicine*. 1988;108(1):7-13.
- [6] Lim S, Lee M. A Computer Aided Diagnosis Algorithm for Classification of Malignant Melanoma Based on Deep Learning. *Journal of the Korea Society of Digital Industry and Information Management*. 2018;14(4):69-77.
- [7] Almeida J, Klima O. On the insertion of n-powers. *arXiv preprint arXiv*. 2017;1711.05525.
- [8] Yao L, Poblentz E, Dagunts D, Covington B, Bernard D, Lyman K. Learning to diagnose from scratch by exploiting dependencies among labels. *arXiv preprint arXiv*. 2017;1710.10501.
- [9] Wang X, Peng Y, Lu L, Lu Z, Bagheri M, Summers RM. ChestX-ray8: Hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases. In *Proceedings of the IEEE conference on computer vision and pattern recognition*; 2017; 2097-2106.
- [10] Kim JY, Ye SY. Diagnostic Classification of Chest X-ray Pneumonia using Inception V3 Modeling. *Journal of the Korean Society of Radiology*. 2020;14(6):773-780.
- [11] Szegedy C, Liu W, Jia Y, Sermanet P, Reed S, Anguelov D, Rabinovich A. Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition*; 2015;1-9.
- [12] Lambert J, Sener O, Savarese S. Deep learning under privileged information using heteroscedastic dropout. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*; 2018;8886-8895.
- [13] Song HJ, Lee EB, Jo HJ, Park SY, Kim SY, Kim HJ, Hong JW. Evaluation of Classification and Accuracy in Chest X-ray Images using Deep Learning with Convolution Neural Network. *Journal of the Korean Society of Radiology*. 2020;14(1):39-44.
- [14] Google. Advanced Guide to Inception v3 on Cloud TPU. <https://cloud.google.com/tpu/docs/inception-v3-advanced?hl=en>
- [15] 이종근, 김선진, 박내정, 김동우, 안재형. 흉부 디지털 영상의 병변 유무 판단을 위한 딥러닝 모델. *한국정보통신학회논문지*. 2020;24(2):212-218.
- [16] Song KD, Kim M, Do S. The latest trends in the use of deep learning in radiology illustrated through the stages of deep learning algorithm development. *Journal of the Korean Society of Radiology*. 2019;80(2):202-212.
- [17] Hinton GE, Srivastava N, Krizhevsky A, Sutskever I, Salakhutdinov RR. Improving neural networks by preventing co-adaptation of feature detectors. *arXiv preprint arXiv*; 2012;1207.0580.
- [18] Philbin EF, Garg R, Danisa K, Denny DM, Gosselin G, Hassapoyannes C. Digitalis Investigation Group. The relationship

- between cardiothoracic ratio and left ventricular ejection fraction in congestive heart failure. Archives of internal medicine. 1998;158(5):501-506.
- [19] Tieleman T, Hinton G Divide the gradient by a running average of its recent magnitude. coursera: Neural networks for machine learning. Technical Report; 2017.
- [20] 정원준. 국내 인공지능 (AI) 의료기기 현황 및 규제 이슈. 주간기술동향. IITP; 2018.
- [21] Japkowicz N, Shah M. Evaluating learning algorithms: a classification perspective. Cambridge University Press; 2011.