

챗GPT를 활용한 자기소개서 평가 성능 및 업무자동화 가능성에 대한 연구

윤옥지* · 구요한** · 장홀***

〈요약〉

인공지능은 수많은 업무 영역에서 패러다임의 전환을 가져오고 있으며 인사관리 분야에서도 다양한 활용방안이 발굴되고 있다. 특히 챗GPT의 등장으로 기존 단순한 업무의 자동화에 그쳤던 인공지능의 활용이 보다 복잡한 인사담당자의 업무에 적용될 잠재력을 얻게 되었다. 그러나 챗GPT의 업무수행 성능을 구체적으로 검증한 연구는 부재한 상황이며, 이에 본 연구는 인사담당자의 업무, 특히 자기소개서 평가에 대한 챗GPT의 성능을 분석해보고자 하였다. 84개의 자기소개서와 평가표를 23,940개의 단위로 구분하여 챗GPT에게 평가를 요청하였으며, 그 결과를 다면적으로 분석하고 인간 평가자의 평가 결과와 비교하였다. 분석 결과, 챗GPT의 주요 하이퍼파라미터(hyperparameter)인 온도(temperature)가 증가함에 따라 오류가 발생할 확률이 증가하고 평가의 일관성이 감소하는 것을 확인할 수 있었다. 또한 챗GPT는 다양한 평가등급을 골고루 부여하기보다 특정 등급에 편향적으로 부여하는 경향이 나타나는 것을 확인했으며, 그러한 다양성 수준은 평가표에서 어떠한 평가등급 명칭을 활용했느냐에 따라 상이했다. 다음으로 챗GPT 평가 결과를 인간 평가자의 자기소개서 평가와 비교해 본 결과, GPT-3.5 모델에서는 최대 0.34($p < .01$), GPT-4 모델에서는 최대 0.60($p < .001$)의 유의미한 양(+)의 상관관계가 확인되었다. 마지막으로 챗GPT가 상위점수를 부여한 지원자가 실제 채용 합격자와 일치하는 정도를 비교한 결과, GPT-3.5 모델은 평균 61%, GPT-4 모델의 경우는 평균 83%로 나타났다. 이러한 결과는 챗GPT가 자기소개서 평가 업무를 자동화하거나, 또는 인간 평가자의 업무를 지원하는 데 활용될 수 있다는 것을 보여준다. 특히 하나의 자기소개서를 평가하는 데에 소요되는 시간은 1분 이내이며, 비용 또한 \$0.03 수준인 점을 고려했을 때, 챗GPT의 잠재력을 주목할 만하다. 이러한 연구결과를 기반으로 결론에서는 연구의 이론적, 실무적 시사점 및 향후 연구의 방향성에 대해 기술하였다.

키워드: 인공지능, 챗GPT, 생성형 AI, 채용, 업무자동화

논문접수일 2023년 8월 4일

논문수정일 2023년 9월 28일

게재확정일 2023년 10월 23일

* 제1저자, (주)에프엠어소시에이츠 선임 컨설턴트, E-mail: wjyoon@fma-consulting.com

** 공동저자, 한양대학교 교육공학 박사과정, E-mail: yohankoo@hanyang.ac.kr

*** 공동저자, 한양대학교 조직인사전공 박사, E-mail: blessjh@hanyang.ac.kr

I. 서론

인공지능(artificial intelligence, AI)의 등장은 다양한 분야에서 패러다임의 변화를 가져오고 있다. 특히 2022년 11월 OpenAI의 챗GPT 서비스가 등장하면서 인공지능은 전례 없는 관심을 받고 있다. 챗GPT는 생성 AI(generative AI) 기술을 활용한 최신의 언어 모델이다(van Dis et al., 2023). 챗GPT는 자연어처리 기술을 활용하여 사용자의 질문을 이해하고, 질문의 의도에 맞는 자연스러운 답변을 제공할 수 있다. 단순 대화형 응답뿐만 아니라 언어 번역, 콘텐츠 생성, 텍스트 요약, 정보 제공 등 광범위한 부분에서 강력한 성능을 보여준다(김태원, 2023). 챗GPT는 누구나 쉽게 접근할 수 있는 채팅의 형태로 무료 서비스를 제공하여, 출시된 지 5일 만에 100만 명의 사용자를 확보하는 등 폭발적인 관심을 얻었다. 현재 세계적으로 1.5억 명 이상의 사용자가 챗GPT를 사용하고 있다(딜로이트, 2023). 챗GPT를 업무에 적용하는 다양한 사례들 또한 등장하고 있다. 챗GPT는 이메일 등 일반적 글쓰기 지원, 개발자를 위한 코딩 어시스턴트, 카피라이팅, 웹사이트 콘텐츠 제작 등 다양한 업무 분야 수행에 대한 잠재력을 보였다(윤준탁, 2023).

전통적으로 인사관리에 있어 인공지능의 활용은 단순한 업무의 자동화에 국한되어 왔다. 자연어를 그대로 이해하고 이를 응답할 수 있는 챗GPT의 능력은 보다 복잡한 인사관리 업무에 대한 활용 가능성을 시사한다(Nuzula & Amri, 2023). 일례로 기업에서 채용하고자 하는 포지션에 대한 정보를 챗GPT에 제공하고, 직무기술서와 채용공고를 자동으로 생성하는 방안이 제시된 바 있다(Di

Meglio, 2023). 미국의 Teal사는 구직자의 관점에서 채용공고에 맞는 개인화된 이력서, 자기소개서, 링크드인 프로필까지 챗GPT를 활용해 자동으로 작성할 수 있는 서비스를 제공하고 있다(Zneimer, 2023). 미국인사관리협회(society of human resource management, SHRM)에 게재된 “챗GPT와 HR: HR 전문가를 위한 입문서(ChatGPT and HR: A Primer for HR Professionals)”에 따르면, 다음과 같은 인사관리 업무를 챗GPT가 수행될 수 있다고 제안되기도 하였다: ① 직무기술서 작성 ② 업무매뉴얼 작성 및 관리 ③ 오퍼레터 초안 작성 ④ 인사 법률 및 규정 확인 ⑤ 리포트 요약 ⑥ 직원 설문조사 생성 및 감정 분석 ⑦ 관리업무 자동화 ⑧ 개인화된 경력개발계획 설계 ⑨ 성과점검 준비 ⑩ 이력서 스크리닝 ⑪ 인터뷰 질문 구성 ⑫ 시장 임금 조사 ⑬ 직원 셀프서비스 제공(Navara, 2023).

하지만 여전히 의문이 존재한다. 인공지능, 특히 챗GPT가 인사관리 분야에서 진정으로 인간의 업무를 대체하고 자동화할 가능성이 있을까? 지금까지 인공지능과 인사관리 분야에 관한 다양한 연구가 진행되었음에도 구체적인 실험을 통해 인공지능과 인간 인사담당자의 성과를 비교한 연구는 거의 이루어지지 않았다. 인공지능 활용의 잠재력과 한계에 대한 귀중한 인사이트를 얻기 위해서는 인공지능과 인간을 비교하는 정량적인 연구가 필요하다. 본 연구는 이러한 필요성에 따라 자기소개서 평가에 있어 인간과 챗GPT의 성능을 비교하는 것을 목표로 한다.

특히 본 연구에서 '자기소개서 평가'를 연구의 대상으로 삼은 이유는 다음과 같다. 첫째, 챗GPT는 텍스트 데이터를 입력(input)으로 처리할 수 있으므로 본 실험에서는 텍스

트 기반의 자기소개서를 사용하는 것이 타당하다. 비록 최근 인공지능이 이미지와 같은 다양한 형태의 데이터를 처리할 수 있는 다중모달모델(multimodal model)의 형태로 발전하고 있으나, 가장 대중적으로 활용되고 있는 챗GPT에서는 현 시점까지 텍스트 데이터만을 입력할 수 있다.¹⁾ 둘째, 자기소개서 평가는 인간평가자와 챗GPT의 평가 환경의 차이를 비교적 최소화할 수 있다. 기업의 의사결정에는 다양한 외부 요인들이 개입되기 때문에, 주어진 데이터만을 활용할 수 있는 챗GPT와 맥락을 이해하고 있는 인간을 단순 비교하기 어렵다. 실제로 승진심사 및 성과평가 등에 대한 인간평가자의 판단은 기업 내부 상황과 맥락에 대한 이해를 바탕으로 이루어진다. 자기소개서 평가 또한 외부 요소의 간섭을 완전히 배제할 수는 없으나, 자기소개서와 평가표라는 데이터에 기초해 평가가 이루어진다는 점에서 상대적으로 인간과 챗GPT의 평가 환경을 유사하게 관리할 수 있다. 마지막으로 채용 분야는 국내외에서 인공지능 기술의 활용이 활발히 이루어지고 있는 인사관리 분야이다. 국내 채용 패러다임이 정기 공개채용에서 상시채용으로 변화하고 있다(조용성, 2021). 이에 따라 기업은 채용 과정의 시간과 비용을 감축하고자 자기소개서, 면접, 인성평가 등에서 인공지능을 활용하고 있다. 더불어, 챗GPT를 활용하여 인공적으로 생성된 자기소개서를 검증해야 하는 새로운 과제 또한 마주하고 있다. 이러한 배경을 고려했을 때, 자기소개서 평가 과정을 챗GPT로 자동화할 때 얻을 수 있는 실무적 가치가

높다고 볼 수 있다.

본 논문의 구성은 다음과 같다. 2장에서는 챗GPT와 인사관리에 대한 관련 선행 연구를 검토하였다. 3장에서는 본 논문의 연구 대상과 연구 방법에 대해 설명하였으며, 4장에서는 챗GPT와 인간 평가자의 자기소개서 평가 능력의 비교를 중심으로 연구 분석 결과를 제시하였다. 마지막으로 5장에서는 본 연구의 시사점, 한계점 및 향후 연구 방향에 관해 기술하였다.

II. 이론적 배경

2.1 국내 채용제도에서 자기소개서가 가지는 의미

1980년대 공개채용 문화의 대두로 국내 채용시장이 체계적으로 형성된 이후, 자기소개서는 기업과 구직자를 잇는 가교로써 채용제도의 중요한 프로세스를 담당해왔다. 이종구(2022)는 국내 기업들의 자기소개서 변화 양상을 고찰하며, 2014년 이후 국내 채용환경에서 자기소개서의 중요성이 높아지고 있음을 설명했다.

해당 연구에서는 1980년대 이후 최근 40여 년간 한국 대기업들의 자기소개서 전개양상을 비교 분석하였다. 1980년대에는 채용과정에서 필기시험의 중요도가 높아 당락에 있어 자기소개서가 미치는 영향력이 낮았다. 그러나 1990년대 필기시험이 폐지되는 현상으로 자기소개서의 중요성이 주목받기 시작

1) 현재 챗GPT는 Plugin과 Advanced Data Analysis 등의 기능 확장을 통해 음성, 이미지, 영상 등 다양한 형태의 데이터를 처리할 수 있음. 본 논문의 내용은 작성시점 당시의 챗GPT 기능을 반영하고 있으며, 그 이후에 새롭게 업데이트된 기능에 대한 내용은 다루고 있지 않음.

하여, '성장 과정, 지원동기, 성격의 장단점' 등 면접의 기초자료로 주로 활용되었다. IMF 이후 스펙 열풍으로 인해 자기소개서의 상대적 비중이 감소하였고, 그 항목 또한 자격증, 공모전 등 스펙을 반영하여 쓸 수 있는 형태로 변형되었다. 그러나 최근 국내 기업에서 직무 중심 채용이 대두되며 자기소개서의 중요성이 다시금 커지고 있다. 특히 2014년 고용노동부와 대한상공회의소가 핵심 직무역량 평가모형을 개발하는 것이 중요한 분기점이 되었다. 지원직무에 대한 경험과 이해를 판단할 수 있는 재료로써 자기소개서가 활용되기 시작하면서, 이러한 내용을 자기소개서에 얼마나 잘 녹여내는가가 서류전형의 합격을 좌우하는 핵심 요소가 되었다. 경영 환경이 지속적으로 변화함에 따라 높은 스펙이 채용 후 성과를 보장하는 것이 아니며, 기본적인 직무역량이 높을수록 조직에 대한 기여도가 높다는 인식이 확산되었다(이종구, 2022).

즉, 최근 직무 중심 채용의 확대로 인해 직무에 대한 역량을 검증할 수 있는 자기소개서의 중요도가 높아지고 있다. 그러나 정량적으로 평가할 수 있는 스펙에 비해 자기소개서는 평가하기 어렵고 인사담당자는 채용에 많은 시간을 쏟게 된다. 이에 따라 인공지능을 활용하여 이를 자동화하고자 하는 요구가 높아지고 있는 바, 본 연구의 중요성과 의미를 다시 확인할 수 있다.

2.2 챗GPT의등장이 기업 환경에 미치는 영향

2022년 11월 OpenAI의 챗GPT가 등장한 이래 다양한 측면에서 챗GPT의 성능을 검증하는 연구가 이루어지고 있다.

우선, “GPT-4 기술보고서(GPT-4 Technical Report)”에서는 이미지와 텍스트 입력을 받아 텍스트 출력을 생성할 수 있는 대규모 멀티모달(multimodal) 모델인 GPT-4 기술에 관해 설명하고 있다(OpenAI, 2023). GPT-4는 문서에서 다음 토큰을 예측하도록 사전 학습된 트랜스포머(transformer) 기반의 모델이다. 해당 연구에서는 다양한 실제 상황(real world scenario)을 가정하여 GPT-4의 성능을 확인했는데, 대부분의 상황에서 인간에 비해 낮은 성능을 나타냈다. 다만, 변호사 시험에서 상위 10%의 점수로 합격하는 등, 학술 시험 및 전문직 시험 분야에서는 인간과 유사한 성능을 보였다(OpenAI, 2023).

다음으로 챗GPT와 같은 대형언어모델(large language model)이 미국 노동시장에 미치는 영향에 대해 연구한 “대형 언어 모델의 노동시장에 대한 잠재적 영향력에 대한 초기 연구(GPTs are GPTs: An Early Look at the Labor Market Impact Potential of Large Language Models)”에서는 근로자의 업무가 챗GPT로 인해 어떻게 변화하는지 설명했다(Eloundou et al., 2023). 해당 논문에서는 인간 전문가와 GPT-4가 함께 미국 노동시장의 각 직무와 대형언어모델 간의 연관성을 평가했다. 분석 결과, 미국 노동자의 80%가 업무의 최소 10% 영향을 받을 수 있으며, 특히 19%의 노동자들은 업무의 최소 50%가 챗GPT에 의해 영향을 받을 것으로 나타났다. 특히 고소득 직종일수록 챗GPT로 인해 더 큰 영향을 받을 수 있다(Eloundou et al., 2023).

앞서 언급한 연구들은 챗GPT의 기본적인 성능과 일반적인 사회적 영향에 초점을 맞추고 있지만, 구체적인 특정 과업에 대해 챗GPT의 수행 성능을 연구하고 자동화 가능성

을 탐구하는 연구 또한 이루어지고 있다. 예를 들어, 이데올로기 스케일링(Wu et al., 2023), 입법안 분류(Nay, 2023), 인지 심리학 과제 해결(Binz & Schulz, 2023), 설문조사 연구를 위한 인간 샘플 시뮬레이션(Argyle et al., 2023) 등 광범위한 작업에서 챗GPT가 우수한 성능을 발휘하는 것으로 나타났다.

특히 “텍스트 주석 작업에 대한 챗GPT와 크라우드워커의 성능 비교(ChatGPT Outperforms Crowd-Workers for Text-Annotation Tasks)” 연구는 2,382개의 트윗 샘플에 대하여 인간과 챗GPT의 텍스트 주석 작업 성과를 실험을 통해 정량적으로 비교했다는 점에 주목할 만하다(Gilardi et al., 2023). 해당 연구에서 저자는 텍스트 주석 작업에 있어 챗GPT가 인간 크라우드워커에 비해 우월하다고 결론지었다. 챗GPT의 비교군이 되었던 크라우드워커는 MTurk(Amazon Mechanical Turk)라는 크라우드 워커 플랫폼에서 MTurk 마스터로 분류되는 숙련된 텍스트 주석 작업자 2명으로 구성되었다. 작업의 결과를 비교했을 때, 주석 작업의 정확도(zero-shot accuracy)는 5개 과제 중 4개 과제에서 챗GPT의 성능이 더 높게 나타났다. 또한, 각 그룹별 평가자 간 일치도(intercoder agreement)를 비교한 결과 5개 과제 모두에서 챗GPT의 성능이 높게 나타났다. 특히 챗GPT의 주석 당 비용이 \$0.003 미만으로 크라우드워커에 비해 약 20배 저렴한 점을 고려할 때, 챗GPT는 인간 평가자의 대체재로서 텍스트 주석 작업의 효율성을 획기적으로 높일 수 있는 잠재력을 보여주었다(Gilardi et al., 2023).

2.3 챗GPT와 인사관리

챗GPT의 인적자원관리에서의 활용과 관련한 국내외 연구는 아직 초기 단계에 있다. Sebastian(2023)의 연구에서는 인사관리에서 챗GPT를 활용할 수 있는 방안과 마주하게 될 어려움에 대해 논의되었다. 해당 연구에서 챗GPT의 활용방안으로 ① 신입사원의 온보딩 프로세스 상에서 지속적인 정보 및 지원 제공, ② 휴가 신청 등 직원 지원 작업에 대한 자동화 ③ 인사데이터 수집 및 분석 ④ 모집(recruiting) 과정에서 지원자 대응 및 스크리닝 절차 자동화 등을 제시했다. 반면, 챗GPT를 인사관리에 활용함으로써 발생할 수 있는 잠재적 어려움으로 ① 민감한 개인정보에 대한 데이터 보안 ② 학습 데이터에서 발생할 수 있는 편향성 문제 ③ 복잡한 과제를 부여 받았을 때 발생할 수 있는 오류 가능성 ④ 레거시 인사 시스템 또는 플랫폼과의 통합 문제를 극복해야 한다고 설명했다(Sebastian, 2023).

다른 연구에서는 성과관리 제도상에서 직원에게 실시간 피드백 및 코칭을 제공하는 데 활용할 수 있으며, 직원 행동을 분석하여 개인화된 경력개발 및 교육훈련 프로그램을 설계하는 데에도 챗GPT가 활용될 수 있다는 점을 제시되기도 했다(Nuzula, 2023). 사용자가 아닌 구직자의 입장에서 챗GPT를 활용할 수 있는 사례에 대한 분석도 이루어졌다. 구직자는 챗GPT를 통해 자기소개서 작성, 지원 이메일 작성, 면접질문 준비 등을 요청할 수 있으며 인사담당자가 챗GPT의 자기소개서와 실제 구직자가 작성한 자기소개서를 구분할 확률은 평균적으로 50%에 불과하다는 것을 확인했다(Nuzula, 2023).

국내 연구에서는 챗GPT의 등장으로 촉발

된 일반 인공지능 시대에서 채용 시 고려해야 할 요소로서 증강지능(augmented intelligence)이 연구되기도 했다(이중학 외, 2023). 해당 연구에서는 증강지능의 다섯 가지의 구성 요소로 기술적 이해, 의사소통, 상황 판단과 지속적인 학습, 공동 의사결정, 유연성을 정의하며 향후 국내기업이 채용 기준으로서 인공지능과의 협업 능력에 주목해야 한다는 점을 주장하였다(이중학 외, 2023).

챗GPT의 등장으로 인해 기업은 인적자원 관리, 특히 채용제도 변화에 대한 요구를 마주하고 있다. 앞선 연구에서 살펴본 바와 같이, 인공지능의 발전으로 인해 수많은 핵심 직무의 변화가 일어나고 있다. 변화하는 환경에 대응하기 위해서는, 전반적인 혁신만을 시도하는 것보다 점진적인 접근 방식을 추구하는 것이 조직의 생존에 유리하다(Fallon-Byrne & Harney, 2017; Freeman & Hannan, 1989). 이러한 대응은 전략적 측면에서 외부 환경과의 상호작용만을 고려하는 것이 아니라, 조직의 내부 요인 간의 상호작용에도 밀접한 관계가 있다(Hanelt et al., 2021). 특히 조직의 핵심 자원 중 하나인 인적자원의 관리에 대한 중요도가 높아지고, 인력의 선발에 있어 더욱 효율적이고 효과적인 방법을 탐색할 것을 요구받고 있다. 인력 선발의 효율적 도구를 도입하여 선구적으로 나서거나 혹은 적응하지 못하면 시장경쟁에서 우수한 인력을 확보하지 못하게 될 것이며, 이는 조직 경쟁력의 하락으로 연결될 것이다(Cleveland et al., 2015).

Ⅲ. 연구대상 및 연구방법

본 연구에서는 채용의 핵심 프로세스인 자기소개서 평가 업무에 있어 챗GPT의 성능을 확인하고자 한다.

3.1 연구대상

3.2.1 자기소개서

본 연구는 국내 소재의 한 기업(이하, A기업이라 함)에서 활용된 자기소개서를 활용하여 진행되었다. 인간 평가자로 참여한 인원이 모두 인사 또는 채용 직무 담당자라는 것을 고려하여 인사 직무의 자기소개서를 활용하였다. 또한 경력직 채용이 구직자의 기존 경력 및 성과를 중요시하는 반면, 저연차 직원의 채용에 있어 자기소개서의 중요도가 높다는 점을 고려하여 인턴십 프로그램에 활용된 자기소개서를 활용하였다.

본 연구에서 활용된 자기소개서의 개수는 총 84개이며, 이는 84명 지원자의 자기소개서를 활용했음을 의미한다. 자기소개서는 총 4개의 문항으로 구성되어 있으며 그 내용은 <그림 1>과 같다.

3.2.2 평가표

본 연구에는 등급별 척도와 점수가 구체적인 평가표로 정의된 평가표를 활용하였다. 채용 당시 A기업에서 기업의 철학 및 직무특성을 고려한 인재상이 수립되었고, 인재상에 기반한 평가표 고도화 작업이 이루어졌다. 본 연구에서 평가표의 역할은 주관적인 평가가 아닌 객관적 평가기준을 제시하여 챗GPT와 인간 평가

1번 문항	인턴십에 지원하게 된 동기와 활동을 통해 얻고 싶은 것이 무엇인지 서술하시오 (500자 이내)
2번 문항	본인이 관심있는 HR 분야를 한 가지 골라 해당 분야에 대해 설명하고, 그 분야에 관심을 가지게 된 이유를 서술하시오 (500자 이내)
3번 문항	본인이 생각하는 협력의 가치란 무엇인지 설명하고, 그러한 생각을 가지게 된 계기를 서술하시오 (700자 이내)
4번 문항	현재에 안주하지 않고, 계속해서 성장하기 위해 노력했던 경험에 대해 서술하시오 (700자 이내)

<그림 1> 자기소개서 문항

[평가항목 1] 본인에게 성장이 필요한 부분을 발견했는가?			
A	본인에게 성장이 필요한 부분을 언급하고, 그러한 생각을 하게 된 과정이 적절히 드러난다.	6점	
B	본인에게 성장이 필요한 부분을 언급했으나, 그러한 생각을 하게 된 과정이 적절하게 드러나지 않는다.	3점	
C	본인에게 성장이 필요한 부분이 무엇인지 드러나지 않는다	1점	
가산점	타인이나 외부 상황에 의해서가 아니라 스스로 본인의 성장을 위해 고민한 흔적이 드러난다.	2점	
[평가항목 2] 본인의 성장을 위해 기울인 노력을 적절하게 서술했는가?			
A	본인의 성장을 위해 기울인 노력이 구체적으로 드러나며, 문제인식과의 인과관계가 적절하게 이루어진다.	6점	
B	본인의 성장을 위해 기울인 노력을 구체적으로 작성했으나, 문제인식과의 인과관계가 명확히 드러나지 않는다.	3점	
C	본인의 성장을 위해 기울인 노력이 잘 드러나지 않는다.	1점	
[평가항목 3] 성장했던 경험을 통해 본인이 배운 점 또는 느낀 점이 적절하게 드러나는가?			
A	성장했던 경험과 본인이 배운 점/느낀 점을 연결시켜 구체적으로 서술했다.	8점	
B	본인이 배운 점/느낀 점이 드러나지만, 성장했던 경험과의 연관성이 적절하지 않다.	4점	
C	본인이 배운 점/느낀 점이 잘 드러나지 않는다.	1점	
[평가항목 4] 문서작성능력			
A	답변 전반에 걸쳐 말하고자 하는 의도가 명확히 드러나고, 특별히 나무랄 데가 없다.	3점	
B	답변의 의도는 드러나지만, 문장의 주술/단어의 선택/맞춤법/띄어쓰기 등이 적절하지 못하다.	2점	
C	답변의 의도를 확인하기 어렵다.	1점	

<그림 2> 자기소개서 평가표 예시: 4번문항, 총 25점

자의 평가 성능을 원활히 비교할 수 있도록 하는 것이다. 또한 평가표에는 점수가 구체적으로 정의되어 있어 챗GPT의 성능을 정량적으로 비교할 수 있는 근거가 된다.

<그림 2>는 자기소개서 4번 문항에 해당하는 평가표이다. 평가항목의 척도 구성은 두 가지 유형이 존재한다. 3단계 척도로 구성된 항목의 경우 A, B 또는 C 등급 중 하나를 선택하여 부여하는 형태이며, 이후 분석에서 그 등급명칭을 변수로 조작하여 활용하였다. 두 번째로 가산점의 부여 여부를 결정하는 평가항목이 있으며 이는 이후 분석에서 Yes 또는 No의 2단계 척도로 변경하여 활용하였다.

자기소개서 각 문항에 대한 평가항목이 존재하며 1번, 3번, 4번 문항은 각 5개, 2번 문항은 4개로 총 19개의 평가항목이 존재한다. 평가자는 19개의 평가항목 각각에 대하여 평가등급을 부여하며, 각 등급에 대응하는 점수를 합산하여 평가점수가 산출된다. 이때, 19개 평가항목에서 얻을 수 있는 최대 점수는 100점이다.

3.2.3 챗GPT 및 인간 평가자

본 연구는 챗GPT와 동일한 성능을 가진 API(application programming interface)를 활용하여 진행하였다. 특히, OpenAI에서 제공되는 GPT-3.5 API 제품 중 성능이 가장 뛰어나고 비용 효율적인 모델인 gpt-3.5-turbo API를 활용했다(OpenAI, 2023). 실험은 2023년 4월 22일부터 4월 24일까지 총 3일간 Python 3.10 버전을 활용하여 진행하였으며, 이는 gpt-3.5-turbo API의 3월 23일자 업데이트 버전에 해당한다.

현재 OpenAI에서 제공하는 챗GPT의 모델은 GPT-3.5 버전과 GPT-4의 두 가지 버전

이 있다. 무료로 사용 가능하며 대중적으로 접근성이 높은 모델은 GPT-3.5 모델이다. 반면, GPT-4 모델은 최신 버전의 모델로서 기존 모델인 GPT-3.5 대비 답변의 환영(hallucination)이 적고, 답변의 논리성이 높다(OpenAI, 2023). 그러나 GPT-3.5 버전 대비 응답속도가 느리고, 유료 버전을 구매해야만 활용할 수 있으며, API 사용시 GPT-3.5 버전에 비해 20배~40배 이상의 비용이 발생하는 단점이 있다. 본 연구에서는 실무에서의 활용도를 고려하여 대중적으로 접근성이 뛰어난 GPT-3.5를 중심으로 사용하고, GPT-4 버전은 보완적으로 활용되었다.

한편, 인간 평가자는 당시 A기업에 재직하며 평가를 진행하였던 인사담당자 및 평가담당자 9인으로 구성되어 있으며, 당시 도출되었던 점수 데이터를 활용하여 챗GPT와의 비교를 진행하였다.

3.2 연구방법

챗GPT에 투입(input)으로써 제시하여 질문이나 지시를 하는 텍스트를 프롬프트(prompt)라고 한다. 논문작성 시점 기준, gpt-3.5-turbo API는 텍스트만을 입력할 수 있으므로 자기소개서, 평가표 데이터 및 평가에 대한 안내는 모두 텍스트 프롬프트를 통해 챗GPT에게 제공하였다. 모든 평가에 대해서는 새로운 채팅 세션을 생성하여 이전의 평가 결과가 다음 평가의 결과에 영향을 미치지 않도록 했다. 한글 대비 영어 답변에 있어 챗GPT의 성능 및 속도가 높은 점을 고려하여, 모든 프롬프트는 영어로 제공하였다. 몇 번의 대안을 테스트한 후에 도출된 프롬프트의 형태는 <그림 3>과 같다. <그림 3>의 내용은 4번 문

항에 활용된 프롬프트이며, 동일한 양식의 프롬프트를 활용하여 자기소개서 한 개 문항씩 챗GPT에게 평가를 요청하였다.

챗GPT의 평가 성능을 다차원적으로 검증하기 위해서 2가지의 변수를 활용하였다. 첫째, 온도(temperature)는 출력값의 무작위성을 결정하는 챗GPT의 하이퍼파라미터(hyperparameter)이다. 온도는 0에서 2 사이의 값을 가질 수 있으며, 값이 높을수록 답변의 무작위성이 높아진다. 보다 창의적이고 독창적인 답변을 얻기 위해서는 높은 온도를, 보다 간결하고 정밀한 답변을 얻기 위해서는 낮은 온도를 활용할 것이 권장된다(OpenAI, 2023). 이번 연구에서는 0, 0.5, 1.0, 1.5, 2.0의 다섯 가지 경우로 구분하여 변인으로 활용한다. 둘째, 평가표에 사용되는 등급명칭을 변수로 활용

하였다. 챗GPT가 텍스트 기반의 언어 모델이라는 것을 감안할 때, 등급명칭이 평가 결과에 영향을 미칠 것으로 가정하였다. 3단계 척도의 등급명칭으로 기존 평가표와 동일한 A-B-C 등급(이하, ABC라 한다), 상-중-하 등급에 해당하는 High-Midde-Low(이하, HML이라 한다), 그리고 삼성전자에서 사용되는 평가등급 명칭을 활용하여 Excellent-Good-Unsatisfactory(이하, EGU라 한다) 등 세가지 등급명칭을 활용하였다. EGU 등급의 경우, 삼성전자 임직원 고과 평가는 EX(Excellent), VG(Very Good), GD(Good), NI(Need Improvement), UN(Unsatisfactory)의 5개 등급으로 구성되나, 본 연구에서는 3단계 척도로 축소하여 활용하였다(오세정, 2021)

즉, 각 자기소개서에 대해서 총 15가지의

<SYSTEM PROMPT>

You are a helpful assistant that helps HR Personnel for the cover letter evaluation.

<USER PROMPT>

[Context] The HRM/HRD internship program called “{프로그램명}” is recruiting candidates. HR personnel will evaluate the cover letters submitted by the candidates.

[Info] “{프로그램명}” are proper noun. Provide: cover-letter question, cover-letter content, rubric(criteria w/ rating grades),

[Assistant Need to do] Provide ratings for each criteria in accordance with the rubric, and include a rationale for each rating.

[Question] Please describe your experience of trying to continue to grow and not settle for the present.

[Rubric] #Criteria 1: [Before Growth] Did the applicant identify areas where they needed to grow?

- Grade A: The applicant mentions an area in which they need to grow, and the process by which they came to that thought is adequately demonstrated.
- Grade B: The applicant mentions an area where they need to grow, but does not adequately demonstrate how they came to this thought.
- Grade C: The applicant does not mention an area where they need to grow.

{Criteria 2,3,4,5}

[Content] {자기소개서 내용}

[Assistant] Rating is:

* 중괄호 안의 내용에는 실제 데이터가 포함됨

<그림 3> 챗GPT 제공 프롬프트


변형된 조건이 활용되었으며, 연구는 각 조건마다 평가를 3회 반복 수행하여 이루어졌다. 본 연구의 기반이 되는 데이터는 정리하면 <그림 4>와 같다.

3.3 연구문제


본 연구는 <그림 5>와 같은 연구모형과 같이 일련의 연구문제에 따라 구성될 것이다.

연구문제 1. 챗GPT 자기소개서 평가의 정확성(accuracy)

연구문제 1은 정확성 측면에서 ‘챗GPT가 오류 없이 평가표에 의도한 바대로 자기소개서 평가를 수행할 수 있는가’에 대한 관점으로 챗GPT의 평가 성능을 탐구한다. 지금까지 인사 업무의 자동화는 단순 반복되는 업무에 국한되는 경우가 많았지만, 챗GPT의 등장으로 인해서 좀 더 고도화된 업무에 대



<그림 4> 연구 데이터



<그림 5> 연구 모형

한 자동화를 탐색하게 되었다(Nazzar, 2023). 이러한 맥락에서 챗GPT가 자기소개서 평가와 같은 고차원적인 업무를 오류 없이 안정적으로 수행할 수 있는지 탐색해야 한다. 오류율은 N 이 전체 자기소개서의 개수(본 연구에서, $N=84$ 이다)를 의미하고, n_e 가 오류가 발생한 자기소개서의 개수를 의미할 때 아래와 같이 계산하였다.

$$\text{오류율}(\%) = \frac{n_e}{N} \times 100 \quad (1)$$

이때 오류란 챗GPT가 주어진 평가표 상의 등급을 명시적으로 제시하지 않은 경우를 의미한다. 예를 들어, 평가표 상에서 ABC 등급 중 선택하여 평가등급을 부여할 것이 요구되었으나, 챗GPT가 ‘A+’ 등급을 부여하거나 ‘B or C’ 등급을 부여하거나, 또는 아예 등급을 부여하지 않은 경우 등을 평가오류로 분류했다. 반면, 평가의 내용적인 측면은 고려하지 않았다. 즉, 주어진 평가등급의 정의에 부합하지 않게 평가하였으나 명시적으로 A, B, 또는 C 등급 중 하나를 제시한 경우는 평가오류로 분류하지 않았다. 3회 평가를 반복 수행하는 데에 있어 1회라도 오류가 발생했을 경우 해당 자기소개서는 평가오류로 분류하였다.

기존에 인공지능의 평가 오류율에 대한 허용 가능한 임계값 수준을 다룬 연구는 확인하기 어렵다. 본 연구에서는 허용 가능한 오류율의 최대 수준을 10%로 정의하고, 이를 초과하는 실험조건은 후속 연구문제의 분석 대상에서 제외하였다. 더불어, 해당 실험조건의 오류율이 10%를 초과하지 않아도, 오류가 발생한 개별 자기소개서에 대해서는 모수에

서 제외하고 분석을 진행하였다.

연구문제 2-1. 챗GPT 자기소개서 평가의 일관성(consistency)

연구문제 2-1.에서는 일관성 측면에서 ‘챗GPT가 평가의 반복시행에서 일관적인 평가 결과를 산출할 수 있는가’에 대한 관점으로 챗GPT의 평가 성능을 탐구한다.

챗GPT는 비결정론적이기 때문에 동일한 입력을 제공하더라도 다른 결과를 제시하게 된다(Reiss, 2023). 챗GPT 답변의 무작위성으로 인한 불일치는 챗GPT 평가에 대한 신뢰성을 손상시킬 수 있다. 또한, 챗GPT가 결과를 제시하는 과정은 블랙박스(blackbox)적인 특성을 가지고 있다는 점에서 일관성 검증에 대한 필요성이 높다.

일반적으로 기업에서 자기소개서 평가가 수행될 때, 두 명 이상의 평가자가 평가에 참여한다. 이는 한 사람의 평가자에 의존하는 것보다 다수의 의견을 종합했을 때 평가의 타당성이 높아질 것이라는 기대와 관련이 있다. 이러한 관점은 챗GPT의 평가에서도 활용될 수 있다. 본 연구에서 챗GPT는 과거에 입력된 프롬프트에 대한 기억이 존재하지 않으므로, 각각의 수행은 서로 독립적이다. 따라서 동일한 실험조건(온도, 등급명칭)에 대한 3회 반복수행하여 평가자간 일관성을 측정할 수 있다. 평가자간 일관성은 다양한 지표로서 검증될 수 있다. 특히 본 연구는 범주형 데이터(categorical data)로 평가등급이 도출되는 한편, 연속형 데이터(continuous data)로서 평가점수가 도출된다는 특징을 가진다.

범주형 데이터인 평가등급의 일관성을 측정하기 위해 전체 자료 중에 두명의 평가자

가 같은 범주로 분류한 자료의 퍼센트를 의미하는 퍼센트 일치도(percent agreement) 지표를 활용하였다. 퍼센트 일치도는 계산이 간단하며 평가자 수에 관계없이 적용할 수 있고, 해석하기 용이하기 때문에 실무적으로 유용하다는 장점이 있다(박창언·김현정, 2015). 전체 평가기준의 개수를 N_c 라 하고, 3회 반복 수행에서 모두 동일한 등급으로 부여된 평가기준의 개수를 n_a 라 할 때 퍼센트 일치도는 다음과 같이 계산할 수 있다.

$$\text{퍼센트 일치도}(\%) = \frac{n_a}{N_c} \times 100 \quad (2)$$

이때 N_c 의 최댓값은 1,596(자기소개서 개수 84개, 각 자기소개서당 평가항목의 개수 19개)이되, 연구문제 1의 결과에 따라 오류가 발생하여 제외된 자기소개서가 있는 경우 그 값이 작아질 수 있다. 퍼센트 일치도의 허용 가능한 수준은 척도의 수, 평가자의 수 더불어 분석의 목적에 따라 달라질 수 있다. Graham et al.(2012)은 18개의 실무 평가 연구 결과에 대해 분석한 결과, 퍼센트 일치도 평균 수준은 70%이며 이를 허용 가능한 최소 수준으로 삼아야 한다고 주장했다. 다른 연구에서는 퍼센트 일치도는 척도가 5~7개인 경우에는 최소 75% 수준에서, 척도가 적은 경우에는 최대 90% 이상의 값이 허용된다고 논의된 바 있다(Hartmann, 1977; Steamler, 2004). 이상의 연구 내용을 고려하여, 본 연구에서는 퍼센트의 일치도의 최소 허용 기준을 70%로 정하고, 70% 미만인 경우에 대해서는 후속 연구의 분석 대상에서 제외하였다.

연속형 데이터인 평가 점수의 일관성을 측정

하기 위해서 급내상관계수(intraclass correlation coefficient: ICC3,k)를 사용하였다. 3회 반복 수행에 따라 산출된 자기소개서의 평가점수에 대한 급내상관계수를 측정하였다. 급내상관계수는 0에서 1까지의 값으로 나타나며, 1은 완벽한 일치도를, 0은 일치도가 전혀 없는 것으로 해석된다. ICC의 해석에 관해서 일반적으로 Ciccochetti & Sparrow(1981) 또는 Fleiss(1981)이 제안한 가이드를 사용한다. Ciccochetti & Sparrow(1981)는 0.40 미만일 경우 낮은 신뢰성, 0.40에서 0.59 사이는 양호한 신뢰성, 0.60에서 0.74 사이는 좋은 신뢰성, 0.75 이상은 훌륭한 신뢰성으로 판단한다. Fleiss(1981)는 0.40 미만을 나쁘다고 평가하며, 0.40에서 0.75 사이의 값은 좋은 수준, 0.75이상일 경우 훌륭한 수준이라고 보았다. 이상의 연구들을 참고하여 본 연구에서는 0.75를 급내상관계수의 임계값으로 보았다.

연구문제 2-2. 챗GPT 자기소개서 평가의 다양성(diversity)

연구문제 2-2.에서는 다양성 측면에서 ‘챗GPT는 평가 수행에 있어서 특정 등급에 대한 편향 없이 평가등급을 분배하는가’에 대한 관점으로 챗GPT의 평가성능을 탐구한다. 다양성이란 챗GPT가 부여한 평가 등급의 분포를 의미한다.

평가등급의 균형 있는 분포가 반드시 높은 평가성능을 설명하는 것은 아니지만, 특정 등급만 편향적으로 분포하는 것은 평가의 항상오류(constant error)가 발생된 것으로 해석될 수 있다. 이러한 항상오류는 Javidmehr & Ebrahimpour(2015)의 연구에서 심층적으로 논의된 바 있다. 예를 들어, 챗GPT가 A등급을 대부분 부여하는

경우 평가자가 대상을 지나치게 호의적으로 평가하는 관대화 오류(leniency error)로 해석된다. 반대로 챗GPT가 주로 'C' 등급을 할당하는 경우 지나치게 부정적인 평가경향을 나타내는 가혹화 오류(severity error)로 해석된다. 중간 등급인 'B'의 남용은 중심경향 오류(central tendency error)를 시사한다. 이 편향은 극단적인 판단을 피하는 것을 말하며 중간 규모 옵션을 과도하게 사용하는 것을 말한다. 이러한 항상오류가 발생함으로 인해 평가 분포의 다양성이 감소하고 개별 평가대상자의 수준을 구별하기 어려울 수 있다.

평가등급의 다양성을 정량적으로 측정하기 위해 일반적인 엔트로피에 기초한 지수를 활용하여 계산하였다(성상현 외, 2007). 데이터의 다양성은 다음과 같은 공식에 기초하여 측정된다.

$$\text{다양성} = - \sum_{i=1}^3 P_i (\ln P_i) \quad (3)$$

다양성을 측정함에 있어, 자기소개서 평가 항목 19개 중 2점 척도로 구성된 3개의 항목을 제외하고, 3점 척도로 구성된 16개의 항목만을 활용하였다. 따라서 분석의 대상이 되는 평가항목 개수의 최대값은 4,032(자기소개서 개수 84개, 각 자기소개당 평가항목 개수 16개, 반복시행 3회)이되, 연구문제 1의 결과에 따라 오류가 발생하여 제외된 자기소개서가 있는 경우 그 값이 작아질 수 있다.

위 공식에서 P_i 는 각 평가항목이 부여된 확률을 의미한다. 예를 들어, 4,032개 항목 중 A등급이 2,000번, B등급이 1,500번, C등급이 532번 부여되었다고 가정해보자. 이때 다양성은

약 $0.97 \{= -[2000/4032 * \ln(2000/4032) + 1500/4032 * \ln(1500/4032) + 500/4032 * \ln(500/4032)]\}$ 로 계산된다. 등급분포의 분산이 클수록 더 높은 다양성을 나타내며 이때 최댓값은 $\ln 3$ (약 1.10)이다. 또한, 모든 항목에서 동일한 등급을 부여했을 경우 가장 낮은 다양성을 나타내며 이때 최솟값은 0이다.

다양성 검증을 통해 발생할 수 있는 편향 오류를 고려함으로써 챗GPT의 평가 성능을 종합적으로 확인할 수 있다. 다양성의 최소 허용 수준은 하나의 평가등급이 80% 이상 부여되지 않는 것을 기준으로 설정하였다. 하나의 평가등급이 80% 이상일 때 가능한 다양성의 최대값은 약 $0.64 \{= -[0.8 * \ln(0.8) + 0.1 * \ln(0.1) + 0.1 * \ln(0.1)]\}$ 로 도출되므로, 해당 값을 다양성의 임계값으로 설정하였다.

연구문제 3. 챗GPT 자기소개서 평가의 타당성(validity)

연구문제 3에서는 타당성 측면에서 다양성 측면에서 ‘챗GPT는 평가 성능은 인간 평가자와 비교했을 때 어떠한가’에 대한 관점으로 챗GPT의 평가성능을 탐구한다. 연구문제 2에서 신뢰성과 다양성을 분석한 결과 모든 항목에서 허용기준을 충족한 경우를 연구문제 3의 분석 대상으로 정한다.

타당성을 판단하기 위한 지표로서 먼저 인간 평가자 점수와 챗GPT 점수 간의 상관관계 분석을 시행할 것이다. 1에 가까운 높은 상관관계가 나타날수록 챗GPT의 평가경향이 인간과 유사하다고 볼 수 있다. 두 번째로 실무에서 챗GPT의 활용성을 탐구하기 위하여 채용 프로세스 상에서 실제 이루어진 의사결정과 비교해 볼 것이다. 챗GPT에서 상

위 평가를 받은 지원자와 실제 채용된 최종 합격자 간의 일치도를 측정하는 것을 목표로 한다.

$$Top-k \text{ 일치도}(\%) = \frac{n_k}{N_p} \times 100 \quad (4)$$

N_p 는 채용 프로세스를 거쳐 최종 합격된 지원자의 수를 의미하며(본 연구에서, $N_p = 10$ 이다), n_k 는 챗GPT 평가 점수 상위 k명에 포함된 최종합격자의 수를 의미한다. Top-k 일치도가 높을 경우, 챗GPT를 통한 자기소개서 스크리닝이 채용 프로세스에 유용한 자동화 도구가 될 수 있음을 시사한다. Top-k 일치도가 낮은 경우, 잠재적으로 최종합격할 가능성이 있는 지원자를 챗GPT가 탈락시킬 수 있다는 점에서, 챗GPT를 평가에 활용하는데 있어 리스크가 있음을 암시한다. 본 연구에서는 k를 20명, 30명, 40명, 50명, 60명까지 확대하며 살펴보았다.

연구문제 4. 챗GPT 모델에 따른 비교

챗GPT의 평가 성능을 심도 깊게 확인하기 위하여 연구문제 3에서 시행되었던 인간 평가자와 챗GPT의 타당성 분석 연구를,

GPT-4 모델에 대하여 시행한다. 이때 연구에 활용되는 온도 및 등급명칭 변수는 연구문제 3에서 활용된 조건을 동일하게 활용한다.

IV. 연구결과

4.1 챗GPT 평가의 정확성

<표 1>은 변수(온도 및 평가등급)에 따른 오류율의 변화를 나타낸다. 오류율은 공식 (1)과 같이 전체 자기소개서 84개 중 오류가 발생한 자기소개서의 개수로 계산하였다.

온도가 0.0 또는 0.5일 때는 등급명칭과 관계없이 한 건의 오류도 발생하지 않았다. 온도가 1.0일 경우에는 부분적으로 오류가 발생하였으나 평균적으로 3.2%의 오류율이 나타나는 등 임계값으로 설정한 10%는 초과하지 않았다. 반면, 온도가 1.5인 경우에는 평균 71.0%, 온도가 2.0인 경우에는 모든 경우에서 오류가 발생하였다.

연구문제 1에서 설정한 임계값 10%에 기준하여 온도가 1.5 및 2.0인 경우, 이후 분석 대상에서 전체를 제외하며, 임계값을 넘지 않은 온도 1.0의 경우에 대해서는 오류가 발생한 자기소개서만 분석 대상에서 제외하도록 한다.

<표 1> 오류율

등급명칭	온도				
	0.0	0.5	1.0	1.5	2.0
A-B-C	0.0%(0*)	0.0%(0)	2.4%(2)	69.0%(58)	100.0%(84)
High-Middle-Low	0.0%(0)	0.0%(0)	7.1%(6)	77.4%(65)	100.0%(84)
Excellent-Great-Unsatisfactory	0.0%(0)	0.0%(0)	0.0%(0)	66.7%(56)	100.0%(84)
평균	0.0%	0.0%	3.2%	71.0%	100.0%

주: *괄호 안의 숫자는 오류가 발생한 자기소개서 개수

4.2. 챗GPT 평가의 일관성과 다양성

4.2.1 챗GPT 평가의 일관성

<표 2>는 변수(온도 및 평가등급)들에 대하여, 3회 반복시행 동안 챗GPT가 부여한 평가등급의 퍼센트 일치도(공식 (2))를 보여준다. 퍼센트 일치도는 모든 등급명칭에서 온도가 높아질수록 감소하는 경향이 나타났다. 온도가 0.0일 때는 평균 98.2%의 퍼센트 일치도를 보이며, 3회 반복 시행 동안 대부분의 평가기준에서 챗GPT가 동일한 평가등급을 부여함을 확인할 수 있었다. 반면, 온도가 0.5일 때는 평균 82.4%, 온도가 1.0일 때는 평균 69.2%의 퍼센트 일치도가 나타났다.

<표 3>은 3회 반복시행 동안 챗GPT가 부여한 자기소개서 평가점수에 대한 급내상관계수를 보여준다. 급내상관계수를 계산하기 위해

pinguion(0.53) 라이브러리의 intraclass_corr 함수를 사용하였으며 모델은 (3,k) 모델을 활용하였다. 급내상관계수는 퍼센트 일치도와 마찬가지로 온도가 커질수록 모든 등급명칭에서 감소하는 경향이 나타났다. 또한, 모든 온도에서 ABC 등급명칭의 급내상관계수가 가장 높게 나타났으며, HML 등급명칭의 급내상관계수가 가장 낮게 나타났다.

연구문제 2-1에서 설정한 임계값에 기준하여 퍼센트 일치도가 70% 미만, 급내상관계수가 0.75 미만인 경우 후속 분석대상에서 제외된다. 퍼센트 일치도(55.5%) 및 급내상관계수(0.64)가 미달한 HML 등급명칭의 온도 1.0인 경우와 급내상관계수(0.56)가 미달한 EGU 등급명칭 온도 1.0인 경우가 이후 연구 문제의 분석대상에서 제외되었다.

<표 2> 퍼센트 일치도

등급명칭	온도								
	0.0			0.5			1.0		
	퍼센트 일치도	일치	전체	퍼센트 일치도	일치	전체	퍼센트 일치도	일치	전체
A-B-C	98.4%	1,570	1,596	85.9%	1,370	1,596	77.1%	1,201	1,558*
High-Middle-Low	97.1%	1,550	1,596	70.2%	1,120	1,596	55.5%	822	1,481*
Excellent-Great-Unsatisfactory	99.0%	1,580	1,596	91.0%	1,452	1,596	75.1%	1,199	1,596
평균	98.2%			82.4%			69.2%		

주: *연구문제 1에서 확인한 오류에 따라 전체 모수가 감소함

<표 3> 급내상관계수(ICC)

등급명칭	온도								
	0.0			0.5			1.0		
	ICC	95%	신뢰구간	ICC	95%	신뢰구간	ICC	95%	신뢰구간
A-B-C	.99	0.99-0.99		.86	0.84-0.92		.81	0.72-0.87	
High-Middle-Low	.81	0.74-0.87		.76	0.67-0.83		.64	0.47-0.76	
Excellent-Great-Unsatisfactory	.98	0.98-0.99		.81	0.72-0.87		.56	0.36-0.70	

4.2.2 챗GPT 평가의 다양성

<표 4>는 변수(온도 및 평가등급)들에 대하여, 엔트로피 지수에 기초하여 정의한 다양성(공식 (3))을 보여준다. 다양성은 등급명칭에 높은 영향을 받는다는 것을 확인할 수 있었다. 먼저 ABC 등급명칭은 최소 0.36 ~ 최대 0.48로 상대적으로 낮은 다양성 수준이 나타났다. 특히 모든 온도에서 최고등급인 A등급의 비중이 80% 이상으로 나타나며 평가의 관대화 경향이 나타남을 확인할 수 있었다. EGU 등급명칭은 최소 0.45 ~ 최대 0.56으로 중간 정도의 다양성 수준이 나타났다. 특히 중간등급을 부여하는 비중이 높게 나타나 (77.8% ~ 83.4%) 평가의 중심화 경향을 확인할 수 있었다. 반면, HML 등급명칭의 경우, 최고등급의 비중(48.0% ~ 56.4%)과 중간등급의 비중(42.8% ~ 52.0%)이 비교적 균등하게 나타나는 것을 확인할 수 있었다. 주목할 만한 점은 모든 경우에서 최저등급을 부여할 확률은 1% 미만으로 나타났다는 점이다.

앞서 다양성의 최소허용기준을 0.64로 설정한 바 있다. 다양성 분석결과를 검토해보았

을 때, ABC 등급명칭 및 EGU 등급명칭의 경우, 모든 온도에 대하여 다양성 임계값을 넘지 못하고 편향된 평가결과를 나타내어 후속 분석대상에서 제외되었다. 반면, HML 등급명칭의 경우 모든 온도에서 최소허용기준을 충족하였다.

4.3. 챗GPT 평가의 타당성

연구문제 1과 연구문제 2의 허용기준을 충족하지 못한 경우를 제외하고, 연구문제 3에서는 두 가지 경우(HML 등급명칭/온도 0.0, HML 등급명칭/온도 0.5)에 대하여 챗GPT 평가의 타당성 분석을 진행한다. <표 5>는 인간 평가자의 평가점수와 챗GPT 점수의 평균, 표준편차, 상관관계를 보여준다. 인간 평가자의 평가점수는 84개 자기소개서 각각에 대한 9명 평가자의 평균점수로 산정했으며, 챗GPT의 평가점수는 84개 자기소개서 각각에 대한 3회 반복시행의 평균점수로 산정했다. 상관관계는 scipy(1.10.1) 라이브러리의 pearsonr 함수를 사용하여 계산하였다.

<표 4> 다양성

등급명칭	온도	다양성	최고등급비율	중간등급비율	최저등급비율
A-B-C	0.0	.36	88.2% (3,556*)	11.8% (476)	0.0% (0)
	0.5	.42	85.9% (3,465)	13.7% (552)	0.4% (15)
	1.0	.48	83.2% (3,313)	16.2% (644)	0.7% (27)
High-Middle-Low	0.0	.69	48.0% (1,934)	52.0% (2,098)	0.0% (0)
	0.5	.72	50.6% (2,040)	49.0% (1,975)	0.4% (17)
	1.0	.73	56.4% (2,219)	42.8% (1,685)	0.8% (32)
Excellent-Great-Unsatisfactory	0.0	.45	16.6% (668)	83.4% (3,364)	0.0% (0)
	0.5	.47	17.9% (723)	81.2% (3,306)	0.1% (3)
	1.0	.56	21.6% (871)	77.8% (3,136)	0.6% (25)

주: *괄호 안의 숫자는 부여된 등급 수

<표 5> 평균, 표준편차, 상관관계

변수	평균	표준 편차	1	2	3
1. 인간 평가자	60.10	10.63			
2. High-Middle-Low, 0.0	77.52	5.85	.34**		
3. High-Middle-Low, 0.5	79.00	5.80	.31**	.28**	

* $p<.10$, ** $p<.01$, *** $p<.001$ 양측검정

<표 5>에서 챗GPT의 평가점수와 인간 평가자의 점수의 평균과 표준편차를 비교해본 결과, 챗GPT의 평가점수가 인간 평가자의 점수에 비해 평균점수가 높았으며 편차는 더 작은 것을 확인할 수 있었다. 또한 상관관계를 분석한 결과, 챗GPT의 평가점수는 인간 평가자의 평가점수와 정(+)의 상관관계가 있다는 것이 나타났으나($p<.01$), 그 크기는 0.31~0.34로 높지 않은 수준이었다.

<표 6> Top-k 일치도

k	변수	Top-k 일치도
20	High-Middle-Low 0.0	40%
	High-Middle-Low 0.5	40%
30	High-Middle-Low 0.0	40%
	High-Middle-Low 0.5	50%
40	High-Middle-Low 0.0	70%
	High-Middle-Low 0.5	60%
50	High-Middle-Low 0.0	80%
	High-Middle-Low 0.5	70%
60	High-Middle-Low 0.0	80%
	High-Middle-Low 0.5	80%

다음으로 공식 (4)에 의해 산정된 Top-k 일치도를 분석하였다. $k=20, 30, 40, 50, 60$ 각각에 대한 Top-k 일치도를 <표 6>에서 보여준다. Top-k 일치도는 k 가 커짐에 따라 증가했다. $k=20$ 일 경우 각 변수의 Top-k 일치

도는 40%로 동일했는데, 이는 챗GPT 자기소개서 평가결과의 상위 20명을 스크리닝했을 때, 인간평가에 의해 최종합격된 10명 중 4명 만이 포함되고 10명 중 6명은 챗GPT에 의해 스크리닝될 수 있다는 것을 암시한다. $k=60$ 일 경우 Top-k 일치도는 80%로 나타났는데, 상위 60명을 스크리닝하더라도 최종합격자 중 10명 중 2명은 챗GPT에 의해서 스크리닝될 수 있다는 것을 암시한다.

4.4. 챗GPT 모델에 따른 비교

연구문제 3과 동일한 조건(HML 0.0, HML 0.5)을 바탕으로 모델을 GPT-3.5 모델에서 GPT-4 모델로 변경하여 결과를 살펴보았다.

<표 7>는 인간 평가자의 평가점수와 GPT-4 모델의 점수의 평균, 표준편차, 상관관계를 보여준다. GPT-4 모델의 의 평가점수와 인간 평가자 점수의 평균과 표준편차를 비교해본 결과, GPT-3.5 모델과 마찬가지로 챗GPT의 평가점수가 인간평가자의 점수에 비해 평균 점수가 높았으며 편차는 더 작은 것을 확인할 수 있었다. 또한 상관관계를 분석한 결과, 챗GPT의 평가점수는 인간 평가자의 평가점수와 유의미한 정(+)의 상관관계(0.60~0.53)가 있다는 것이 나타났다($p<.001$).

<표 7> GPT-4 평균, 표준편차, 상관관계

변수	평균	표준 편차	1	2	3
1. 인간 평가자	60.10	10.63			
2. GPT-4 High-Middle-Low, 0.0	80.23	5.97	.60***		
3. GPT-4 High-Middle-Low, 0.5	80.35	5.71	.53***	.49***	

* $p<.10$, ** $p<.01$, *** $p<.001$ 양측검정

GPT-4 모델의 Top-k 일치도는 <표 8>에서 보는 바와 같이 70%(HML 0.0, k=20)에서 100%(HML 0.5, k=60)까지 전반적으로 높은 분포를 보였다.

<표 8> Top-k 일치도

k	변수	Top-k 일치도
20	High-Middle-Low 0.0	70%
	High-Middle-Low 0.5	80%
30	High-Middle-Low 0.0	70%
	High-Middle-Low 0.5	80%
40	High-Middle-Low 0.0	70%
	High-Middle-Low 0.5	90%
50	High-Middle-Low 0.0	90%
	High-Middle-Low 0.5	90%
60	High-Middle-Low 0.0	90%
	High-Middle-Low 0.5	100%

특히, HML 0.5, k=60일 경우 일치도가 100%로 나타났는데 이는 챗GPT에 의해 자기소개서 스크리닝을 실시하더라도 실제 최종합격 의사결정에 영향력을 끼치지 않고, 시간과 비용을 절감할 수 있음을 시사한다.


두 가지 모델을 비교한 결과, GPT-4 모델

이 GPT-3.5 모델에 비해 타당성 측면에서 우수한 성능을 보이는 것으로 나타났다. <그림 6>은 변수와 관계없이 GPT-4 모델이 인간 평가자의 점수와 더 높은 상관관계를 나타내는 것을 보여준다. 또한 각 k값에 대한 Top-k 일치도의 평균을 모델별로 비교한 결과(<그림 7>참조), GPT-4 모델이 GPT-3.5 모델에 비해 우수한 성능을 보였다. 특히, k=30 이하인 경우 GPT-3.5 모델의 Top-k 일치도는 40%, 45%로 절반도 일치하지 않는 모습을 보이는 반면, GPT-4 모델의 경우 75%의 합격자와 일치하는 것으로 나타났다.


V. 결론

5.1 연구결과 요약

본 연구의 결과를 각각의 연구문제별로 살펴보면 다음과 같다. 연구문제 1에서 챗GPT 평가의 정확성을 검토한 결과, 등급명칭과 관계없이 온도가 높을수록 오류율이 높아지는 것을 알 수 있었다. 연구문제 2에서 챗GPT



<그림 6> GPT-4 모델과 GPT-3.5 모델의 인간 평가자 점수와 상관관계 비교



<그림 7> GPT-4 모델과 GPT-3.5 모델의 Top-k 일치도 비교

평가의 일관성을 검토한 결과, 온도가 높을수록 퍼센트 일치율과 급내상관계수가 낮아지는 것을 확인할 수 있었다. 또한 챗GPT 평가의 다양성을 검토한 결과, 등급명칭에 따라 다양성이 달라지며, 본 연구의 조건에서는 HML 등급명칭을 사용할 때 가장 높은 다양성을 보이는 것을 알 수 있었다. 연구문제 3에서는 앞선 연구의 결과에 기초하여 최선의 성능을 보인 두 가지 조건(HML 등급명칭/온도 0.0, HML 등급명칭/온도 0.5)의 챗GPT 평가 결과에 대하여 인간 평가자의 결과와 비교했다. 그 결과 유의미한 양(+)의 상관관계가 확인되었으며, HML 0.0의 경우 상관계수 $0.34(p<.01)$, HML 0.5의 경우 상관계수 $0.31(p<.01)$ 로 나타났다. 연구문제 4에서는 동일한 조건에 대하여 GPT-4 모델을 활용한 비교를 진행하였다. 그 결과, HML 0.0의 경우 상관계수 $0.6(p<.001)$, HML의 경우 상관계수 $0.53(p<.001)$ 로 GPT-3.5 모델에 비해 GPT-4 모델이 인간 평가자의 점수와 상관계수가 높은 것을 알 수 있었다. 또한 챗GPT 평가의 상위 k개(k=20, 30, 40, 50, 60)의 자기소개서에 대한 Top-k 일치도를 비교한 결과, GPT-3.5 모델은 평균 61%, GPT-4 모델

의 경우는 평균 83%로 GPT-4 모델이 더욱 우수한 평가 성능을 나타냈다.

5.2 이론 및 실무적 시사점

본 연구의 의의와 시사점은 다음과 같다. 첫 번째로 챗GPT 성능에 대한 실증적인 연구를 수행했다는 점에서 그 의의가 있다. 인간이 수행하는 업무를 챗GPT가 대체할 수 있을 가능성에 대한 논의는 여러 연구에서 이루어졌지만, 그 성능을 정량적으로 분석한 연구는 드물었다. 본 연구에서는 다양한 변수를 활용하고 반복 실험을 수행함으로써 자기소개서 평가 과정에서 챗GPT의 일관성과 신뢰성을 보장할 수 있는 이상적인 조건을 탐색하였고, 인공지능의 평가와 실제 인사담당자의 평가점수를 비교하여 챗GPT 평가의 타당성을 종합적으로 확인할 수 있었다. 또한, GPT-3.5, GPT-4 등 모델의 차이에 따라 달라지는 성능의 변화도 살펴보았다.

두 번째로 기업의 인공지능 활용 및 도입에 대해 생태학적 관점으로 해석할 수 있다. 챗GPT와 같은 생성형 인공지능의 확산이 일어나고 있으며, 조직은 인공지능을 업무에 도

입하는 방안에 대한 고민을 마주하는 시기다. 본 연구만으로 생성형 인공지능을 활용하지 않는 기업이 반드시 도태된다고 속단하기에는 어려울 것이다. 다만, 우수한 인력을 빠르고 효과적으로 검증할 수 있는 과정을 갖춘 기업에 비해 그렇지 못한 기업이 경쟁력에서 뒤질 수 있다는 것을 암시함으로써 새로운 기술의 도입과 활용이 조직에 미치는 영향을 논의하였다.

세 번째는 본 연구는 사용자의 관점에서 챗GPT의 활용법을 검토하였다. 채용 분야와 관련한 챗GPT의 활용법은 구직자의 입장에서 주로 논의되어 왔다. 최근 하버드 비즈니스 리뷰(Harvard Business Review)에 게재된 “이력서 작성에 챗GPT를 활용해야 하는가(Should you use ChatGPT to write a resume?)”는 챗GPT는 이력서 작성과정에서 신속하게 협업할 수 있는 동료로서 활용될 수 있다고 설명했다(Wilson, 2023). 미국의 Teal과 같은 회사들은 챗GPT를 활용하여 채용공고에 적합한 이력서, 자기소개서, 링크드인 프로필까지 자동으로 생성하는 서비스를 제공하고 있다(Zneimer, 2023). 반면, 사용자의 입장에서 어떻게 챗GPT를 활용할 수 있을 지에 대한 가능성은 대부분 논의되지 않았다. 본 연구는 이러한 공백을 해소하고자, 구직자의 자기소개서를 평가하는 입장에서 챗GPT의 활용가능성을 확인함으로써 사용자 관점에서 해결책을 제시하였다.

마지막으로 본 연구 결과는 기업 및 조직에서 실무적으로 활용될 수 있다. 실험을 통해 챗GPT의 평가 성능을 검증함으로써, 자기소개서 평가를 자동화하고 업무 프로세스를 효율화할 수 있는 잠재력을 확인하는 데 기여했다. 모델에 대한 별도의 학습이나

세부 조정이 없었음에도 불구하고, 챗GPT의 평가 성능은 인간의 평가와 유의미한 수준의 상관관계(최대 0.6)가 있는 것으로 나타났다. 특히, 하나의 자기소개서를 평가하는 데 소요되는 시간은 1분 이내이며, 비용 또한 \$0.03 수준이라는 것을 고려하면 챗GPT의 잠재력은 더욱 주목할 만하다. 또한 인공지능을 자기소개서 평가에 활용할 경우, 채용에 투입되는 시간과 노력이 감소할 뿐만 아니라 평가 과정에서 사람의 편견 개입 가능성을 최소화해 채용의 공정성 및 객관성을 향상시킨다는 점에서도 의미를 찾을 수 있다. 더불어 각 기업의 핵심가치 및 인재상을 자기소개서 문항 및 평가표 설계에 반영함으로써, 기업별 인사 정책에 특화된 형태로 채용 자동화를 도입할 수 있게 한다. 특히, 본 연구의 결과는 중소기업의 채용 과정에서 실무적 시사점을 가진다. 대기업의 경우에는 자체적인 데이터베이스 및 시스템을 구축하여 자기소개서 평가를 자동화하는 사례가 존재하지만, 비용 및 인력의 한계가 존재하는 중소기업은 이를 실현하기 어렵다. 챗GPT는 사용자 친화적인 인터페이스를 기반으로 프롬프트만 입력하면 사용할 수 있어, 중소기업들을 대상으로 보편적으로 활용가치가 높다.

5.3 연구의 한계와 향후 연구

본 연구의 시사점에도 불구하고, 향후 연구에서 보완되어야 할 몇 가지 한계가 존재한다. 첫째, 대부분의 실증 연구와 마찬가지로, 특정 기업을 대상으로 한 연구 표본의 제한성을 고려하여 그 결과를 해석하는 데 있어 주의하여야 한다. 본 연구에서는 인사 직무의 인턴십 지원자에 대한 자기소개서 데이

터를 활용했는데, 직무의 특성 및 인재상이 상이한 채용환경에서도 동일하게 적용될 수 있는지에 관해서는 추가적인 연구가 필요하다. 채용 직무에 따라 자기소개서를 통해 평가하고자 하는 항목이 달라질 수 있으며, 이는 챗GPT의 평가 성능 변화와도 연결될 수 있다. 또한 본 연구에서는 정보 노출에 대한 우려로 활용하기 어려웠으나, 인간 평가자의 경력 및 전문성 등 자격에 대한 제한, 채용 이후 합격자의 업무성과와의 비교, 정성적인 평가 의견에 대한 수렴 등이 이루어진다면 보다 심층적인 연구가 가능할 것이다.

두 번째로, 본 연구에서 확인한 잠재력에도 불구하고 곧바로 실무에서 챗GPT를 활용할 수 있다고 보기 어렵다. 기술수용 모델(technology acceptance model)에 따르면 새로운 정보기술을 사람들이 수용하고자 하는 태도에는 지각된 유용성(perceived usefulness)과 지각된 용이성(perceived ease of use)이 영향을 끼친다(Davis, 1989). 지각된 유용성 관점에서 살펴볼 때, 챗GPT의 성능에 대한 유용성 수준은 조직의 상황에 따라 달라질 수 있다. 본 연구에서 챗GPT의 평가 결과가 인간평가자와 유의미한 상관관계가 있음을 밝혔지만 오차 또한 분명히 존재한다. 비용 효율성과 채용 정확도 중 무엇을 우선시하느냐에 따라 지각된 유용성 수준은 달라지게 될 것이다. 한편, 챗GPT는 입력할 수 있는 글자 수 제한이 존재하며, 한꺼번에 여러 개의 응답을 동시에 요청할 수 없다. 지각된 용이성의 관점에서 고려했을 때, OpenAI에서 제공하는 API를 활용하여 자기소개서 평가를 위한 별도의 사용자 인터페이스를 설계해야 할 필요가 있다. 결론적으로 실무에서 챗GPT를 활용함에 있어서는 1차 심사 등과 같

이 인간 평가자의 판단을 보완하는 도구로 활용하는 등 점진적인 접근방안을 취하는 것이 바람직할 것이다.

셋째, 챗GPT를 실무에 활용하기 위해서는 그 성능을 지속적으로 모니터링할 필요가 있다. 챗GPT는 새로운 데이터의 학습, 사용자 피드백, 모델 설계의 변화 등으로 지속적으로 업데이트되므로 그 성능이 변화하거나, 향상되거나 심지어는 저하될 수 있다. 최근의 연구 결과에 따르면, 2023년 3월 버전에 비해 2023년 6월 버전의 챗GPT의 답변 품질이 저하된 것으로 나타났다. 이러한 현상은 수학 문제 해결, 민감한 질문에 대한 답변, 코드 생성 및 시각적 추론 등의 영역에 걸쳐 나타났다(Chen et al., 2023). 이러한 연구 결과는 챗GPT의 성능을 예측하기 어렵고 단기간에 변화할 수 있음을 보인다. 즉, 챗GPT는 한번 설정하면 모든 것이 해결되는 도구(set-it-and-forget-it tool)가 아니므로, 챗GPT로 한번 자동화 프로세스를 수립하더라도 지속적인 모니터링이 필요하다(Rowland, 2023).

넷째, 챗GPT의 평가 결과는 어떤 프롬프트를 제시하는 지에 따라 큰 영향을 받으며, 연구 결과를 도출하기 위한 최선의 프롬프트 전략을 연구할 필요가 있다(Argyle et al., 2023). 인간 평가자의 경우, 동일한 평가표만 제시된다면 어떠한 표현으로 평가를 요청한다고 하더라도 전체적으로 의미가 유사하다면 평가 결과에 대한 영향을 미치지 않을 가능성이 높다(Reiss, 2023). 그러나 챗GPT는 평가표와 자기소개서를 동일하게 전달하더라도, 프롬프트에 따라 평가를 올바르게 수행하지 못하는 경우도 발견되었다. 프롬프트의 미묘한 변화는 실험에서 변수로 활용하기는 어렵지만, 실제 챗GPT의 평가 성능에는 큰

영향을 미칠 수 있기 때문에 간과하기 어렵다. 최근 ‘생각의 사슬(Chain of Thought)’ 등 챗GPT의 답변 성능을 향상시키는 다양한 프롬프트 전략이 연구되고 있다(Kojima et al., 2023). 자원기반 관점(resource based view)에 따르면 가치있고, 희귀하며, 모방이 쉽지 않고, 대체 불가능한 자원을 확보하는 것이 경쟁우위 확보를 위해 중요하다(Barney, 1991). 챗GPT를 모방 불가능한 조직 고유의 도구로 사용하기 위해서는 조직의 프롬프트 사용 전략을 구체화할 필요가 있다.

마지막으로, 본 연구는 GPT-3.5 버전의 대표적인 모델이자 다양한 챗GPT 관련 웹서비스로 이용되고 있는 gpt-3.5-turbo API를 활용하여 수행되었으며, GPT-4 모델은 일부 연구문제에서만 활용되었다. 해당 논문의 작성 시점에는 GPT-4 모델의 접근성 및 비용 효율성을 고려했을 때 기업 실무에서 활용하기에 어려움이 있지만, 향후 이러한 문제가 개선되어 GPT-4 모델에 대한 접근성이 향상될 것이 기대된다. 특히 본 연구 결과 GPT-4가 GPT-3.5에 비해 뛰어난 평가 성능을 나타내는 것이 확인된 만큼, 향후 연구에서는 GPT-4 모델에 기반한 추가적인 연구가 필요할 것으로 보인다.

참고문헌

- 김현정 · 박창언. (2015). 체계적 문헌고찰에서 평가자 간의 신뢰도 측정. *Hanyang Medical Reviews*, 35(1), 44-49.
- 김태원. (2023). *NIA The AI Report*. 한국지능정보사회진흥원(NIA).
- 델로이트. (2023, 4). *인공지능(AI)이 말을 걸다*. 인간과 대화하고 공감하는 AI의 등장. <https://www2.deloitte.com/kr/ko/pages/technology-media-and-telecommunications/articles/2023/20230420.html>
- 오세정, (2021, 11. 17). *삼성전자, 인사제도 개편... 절대평가 확대 · 동료평가제 도입*. 서울파이낸스. <https://www.seoulfn.com/news/articleView.html?idxno=437956>
- 윤준탁. (2023, 3). *왔다 가는 트렌드 아닌 지배적 혁신 챗GPT와 공존 가능한 활용 방안* 질실 동아비즈니스리뷰. https://dbr.donga.com/article/view/total/article_no/10799/article_no/a_list
- 이종구. (2022). 한국 대기업의 시대별 자기소개서 형태의 전개 양상과 특징 비교분석에 관한 탐색적 연구. *취업진로연구*, 12(2), 1-21.
- 이중학 · 정진우 · 송태경. (2023). 일반인공지능 시대의 채용을 위한 연구: 증강지능(Augmented Intelligence)을 중심으로. *조직과인사관리연구*, 47(2), 113-137.
- 오용성. (2021, 2. 14). *대기업 공채 대신 상시채용 전환 봇물. "필요할 때 인재 뽑겠다"*. YTN. https://www.ytn.co.kr/_ln/0102_202102140623334970
- Argyle, L., Busby, E., Fulda, N., Gubler, J., Rytting, C., & Wingate, D. (2023). Out of one, many: using language models to simulate human samples. *Political Analysis*, 31(3), 337-351.
- Barney, J. (1991). Firm resources and sustained competitive advantage. *Journal of management*, 17(1), 99-120.
- Binz, M., & Schulz, E. (2023). Using cognitive psychology to understand gpt-3. *Proceedings of the National Academy of Sciences*, 120(6), e2218523120.

- Chen, L., Zaharia, M., & Zou, J. (2023). *How is ChatGPT's Behavior Changing Over Time?*. arXiv preprint arXiv:2307.09009.
- Davis, F. D. (1989). Perceived usefulness, perceived ease of use, and user acceptance of information technology. *MIS quarterly*, 13(3), 319-340.
- Di Meglio, F. (2023, february 22). *Can ChatGPT write job descriptions better than you can?*. HR Exchange Network. <https://www.hrexchangenetwork.com/hr-tech/articles/can-chatgpt-write-job-descriptions-better-than-you-can>
- Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2023). *Gpts are gpts: An early look at the labor market impact potential of large language models*. arXiv preprint arXiv:2303.10130.
- Fallon-Byrne, L. & Hamey, B. (2017). Microfoundations of dynamic capabilities for innovation: a review and research agenda. *The Irish Journal of Management*, 36(1), 21-31.
- Firdausa Nuzula, I., & Miftahul Amri, M. (2023). Will ChatGPT bring a new paradigm to HR world? A critical opinion article. *Journal of Management Studies and Development*, 2(2), 142-161.
- Freeman, J., & Hannan, M. T. (1989). Setting the record straight on organizational ecology: Rebuttal to Young. *American journal of sociology*, 95(2), 425-439.
- Gilardi, F., Alizadeh, M., & Kubli, M. (2023). *ChatGPT outperforms crowd-workers for text-annotation tasks*. arXiv preprint arXiv: 2303.15056.
- Graham, M.J., Milanowski, A.T., & Miller, J.B. (2012). *Measuring and promoting inter-rater agreement of teacher and principal performance ratings*. Center for Educator Compensation and Reform.
- Hanelt, A., Bohnsack, R., Marz, D., & Antunes Marante, C. (2021). A systematic review of the literature on digital transformation: Insights and implications for strategy and organizational change. *Journal of Management Studies*, 58(5), 1159-1197.
- Hartmann, D. P. (1977). Considerations in the choice of interobserver reliability measures. *Journal of Applied Behavior Analysis*, 10, 103-116.
- Javidmehr, M., & Ebrahimpour, M. (2015). Performance appraisal bias and errors: The influences and consequences. *International Journal of Organizational Leadership*, 4(3), 286-302.
- Kojima, T., Gu, S. S., Reid, M., Matsuo, Y., & Iwasawa, Y. (2022). Large language models are zero-shot reasoners. *Advances in neural information processing systems*, 35, 22199-22213.
- Navarra, K. (2023). *ChatGPT and HR: A primer for HR professionals*. Society for Human Resource Management. <https://www.shrm.org/resourcesandtools/hr-topics/technology/pages/chatgpt-hr-primer-ai-workplace.aspx>
- OpenAI. (2023). *Gpt-4 technical Report*. arXiv preprint arXiv:2303.08774.
- OpenAI. (2023). *OpenAI API models overview*. <https://platform.openai.com/docs/models/overview>
- OpenAI. (2023). *OpenAI API reference*. <https://platform.openai.com/docs/api-reference/chat>

- Reiss, M. V. (2023). *Testing the reliability of ChatGPT for text annotation and classification: A cautionary remark*. arXiv preprint arXiv:2304.11085
- Rowland, A. (2023, 6, 23). *The Changing Behavior of ChatGPT Over Time*. Cimatri. <https://cimatri.com/the-changing-behavior-of-chatgpt-over-time/>
- Sebastian, Glorin. (2023, May. 28). Hello! This is your new HR assistant, ChatGPT! Impact of AI chatbots on human resources: A transformative analysis. <https://doi.org/10.13140/RG.2.2.21668.86405>
- Stemler, S. E. (2004). A Comparison of Consensus, Consistency, and Measurement Approaches to Estimating Inter-Rater Reliability. *Practical Assessment, Research, and Evaluation*, 9(4), 1-19.
- Wilson, (2023, 5, 31), *Should you use ChatGPT to write a resume?*. Harvard Business Review. <https://hbr.or/2023/05/should-you-use-chatgpt-to-write-a-resume>
- Wu, P. Y., J. A. Tucker, J. Nagler, and S. Messing (2023). *Large language models can be used to estimate the ideologies of politicians in a zero-shot learning setting*. arXiv preprint arXiv:2303.12057
- Zneimer, L. (2023, 8, 18), *How to use ChatGPT to make a resume*. TealHQ Blog. <https://www.tealhq.com/post/3-ways-to-use-chatgpt-ai-for-your-job-search>

■ 저자 소개

윤옥지(Wookji Yoon)

- (주)에프엠어소시에이츠에서 선임 컨설턴트로 근무 중이며, 성균관대학교에서 수학교육과(정) 및 인적자원관리(복수)를 전공하였다. 인사조직분야 경영컨설팅을 전문으로 하고 있으며, 중견~대기업 대상으로 직급, 승진, 평가, 보상 등의 인사제도 설계 등을 주로 수행하고 있다.

구요한(Yohan Koo)

- 한양대학교 교육공학과에서 교수체제설계 및 기업교육연구 전공으로 박사과정을 수료하고, 한양대학교 경영대학에서 선임연구원으로 재직 중이다. 관심 분야는 지식관리, HR 애널리틱스, 커뮤니케이션이다.

장훔(Hwool Jang)

- 한양대학교 경영대학 조직인사전공으로 박사 학위를 취득하고 현재 한양대학교 컬렉티브임팩트센터 연구원으로 재직 중이다. 전략적 인적자원관리, 직무중심 인사제도, 협업적 인적자원관리, 사회적가치 및 ESG에서의 인사제도 운영 등 인사관리 분야에 대한 연구와 함께 HR 애널리틱스, 지식관리 분야의 연구도 진행하고 있다.

〈Abstract〉

A Study on the Performance of ChatGPT in Evaluating Cover Letters and Its Potential to Robotic Process Automation

Wookji Yoon* · Yohan Koo** · Hwool Jang***

Artificial intelligence is revolutionizing various work sectors, including human resource management. With the advent of ChatGPT in particular, AI has moved beyond simple task automation to potentially handle complex duties in HR. Due to the lack of specific studies on ChatGPT's performance, this research focuses on analyzing its efficacy in cover letter evaluation. ChatGPT was used to evaluate 23,940 units derived from 84 cover letters and evaluation sheets, with the results analyzed and compared to human evaluations. We found that an increase in the temperature, ChatGPT's key hyperparameter, led to rising error rates and declining rating consistency. We also found that ChatGPT tended to assign a bias toward certain ratings rather than assigning a variety of ratings evenly, with diversity levels influenced by the rating nomenclature used. Next, we identified significant positive correlations between ChatGPT and human raters, reaching up to 0.34 ($p < .01$) and 0.60 ($p < .001$) for GPT-3.5 and GPT-4 models, respectively. We also found that ChatGPT's top-scoring applicants matched actual hires by 61% for the GPT-3.5 model and 83% for the GPT-4 model. These results suggest that ChatGPT could support or automate cover letter assessments. ChatGPT's potential was found to be significant, given its ability to evaluate a cover letter in under a minute for just \$0.03. Based on these findings, the conclusion discusses the theoretical and practical implications of the study and directions for future research.

Key words: artificial intelligence, ChatGPT, generative AI, employment, robotic process automation

* First Author, Associate Consultant, FMASSOCIATES, E-mail: wjyoon@fma-consulting.com

** Coauthor, Ph.D. Candidate, Hanyang University, E-mail: yohankoo@hanyang.ac.kr

*** Coauthor, Doctor, Hanyang University, E-mail: blessjh@hanyang.ac.kr