

의료인공지능

2025년 2학기

이은주

분류/회귀 기초

강의 목표

- KNN
 - 모델 기반 학습과 사례 기반 학습을 이해한다.
 - k-최근접 이웃의 개념 및 동작 원리를 이해한다.
 - 데이터 간 유사도 측정 방법인 거리 측도를 이해한다.
 - k-최근접 이웃을 활용한 분류와 회귀를 이해한다.
- Decision Tree
 - 의사결정 트리의 개념에 대해서 이해한다.
 - 엔트로피와 정보 이득에 대해서 이해한다.
 - 불순도와 지니계수를 이해한다.
 - 데이터의 분산을 통한 회귀 방법을 이해한다.
 - 의사결정 트리의 성장 과정에 대해서 이해한다.

K-최근접 이웃


(K-Nearest Neighbor)

- 모델 기반 학습과 사례 기반 학습
- k-최근접 이웃의 주요 개념
- 거리 측도
- k-최근접 이웃을 통한 분류
- k-최근접 이웃을 통한 회귀
- k-최근접 이웃의 하이퍼파라미터
- 코드로 구현하는 k-최근접 이웃

01 모델 기반 학습과 사례 기반 학습


- 모델 기반 학습

- 훈련 데이터로부터 모델 f 의 파라미터(가중치)를 최적화하여 최적의 함수 f^* 생성
- 한 번 모델 생성을 완료하면 테스트 데이터에 대해서는 단순히 함수 f^* 의 연산으로 예측값 도출
- 선형회귀, 로지스틱회귀, 퍼셉트론, 다층 퍼셉트론 등 앞서 배운 모델이 모두 모델 기반 학습 방법




01 모델 기반 학습과 사례 기반 학습

- 사례 기반 학습
 - 별도의 모델을 생성하지 않는 방식
 - 테스트 데이터가 입력될 때마다 학습 데이터를 기반으로 예측값 연산
 - k-최근접 이웃이 대표적인 사례 기반 학습 방법임




02 k-최근접 이웃의 주요 개념

- k 최근접 이웃(k-Nearest Neighbor)
 - 지도학습 방법의 하나로, 새로운 데이터를 기존 데이터와 비교하여 분류하는 알고리즘
- 1-최근접 이웃(k=1)
 - 새로운 데이터에 대해서 기존 데이터와 가장 유사한 데이터는?
→ 해당 데이터와 동일하게 분류
 - k는 근접해 있는 데이터 중 몇 개를 확인할 것인지를 의미한다.




02 k-최근접 이웃의 주요 개념

- k의 값에 따라 새로운 데이터가 어떤 이산형 실제값을 가질지 예측해보자.



02 k-최근접 이웃의 주요 개념

- 3 최근접 이웃($k=3$)
 - $k=3$ 일 때 새로운 데이터는 어떻게 새로운 이산형 실제값을 결정해줄까?
 - 주변 데이터의 이산형 실제값에 따라 다수결로 새로운 이산형 실제값을 결정한다.



03 거리 측도

- 테이블 데이터에서는 근접한 데이터를 어떻게 계산할까? → 거리측도
- 새로운 데이터가 발생한 이후에 실제값 예측 수행됨 → 사례 기반 학습의 특징
 - 아래 표의 데이터로 유클리드 거리와 맨해튼 거리에 대해 알아보자.

키-몸무게 등급에 따른 비만 여부

	몸무게(x_{i1})	키(x_{i2})	비만 여부(y_i)
생도 1	1	0	0
생도 2	2	1	0
생도 3	3	3	0
생도 4	5	2	1
생도 5	5	4	1
생도 6	6	5	1
생도 7	9	2	1
신입 생도	3	4	?


03 거리 측도

- 유클리드 거리

- 가장 많이 사용하는 거리측도 → 고등수학 과정의 직선 거리, 점과 점 사이의 거리
- 대응되는 관측치의 특징벡터 간 차이 제곱 합의 제곱근

$$\text{Euclidean Distance}(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\sum_{j=1}^p (x_{1j} - x_{2j})^2}$$

- p : 데이터(특징 벡터)를 구성하는 성분의 수



03 거리 측도

- 맨해튼 거리

- 일상생활에서는 잘 사용하지 않으나, 머신러닝 혹은 프로그래밍에서 종종 사용
- 실제 뉴욕의 맨해튼과 같은 구획에서 이동할 때는 맨해튼 거리처럼 이동해야함

$$\text{Manhattan Distance}(\mathbf{x}_1, \mathbf{x}_2) = \sum_{j=1}^p |x_{1j} - x_{2j}|$$


-
- p : 데이터(특징 벡터)를 구성하는 성분의 수

$$\text{Manhattan Distance}(\mathbf{x}_3, \mathbf{x}_7) = |3 - 9| + |3 - 2| = 7$$

03 거리 측도




맨해튼 지도



04 k-최근접 이웃을 통한 분류


- k-최근접 이웃 동작 단계
 - 목적: 새로운 데이터의 예측값을 결정하기 위한 3단계 과정
 - 1단계: 거리 계산
 - 모든 학습 데이터와 새로운 데이터 사이의 거리 계산, 유클리드 거리(기본값) 사용
 - 2단계: 가까운 데이터 탐색
 - k 값에 따라 가까운 데이터 탐색(예시: $k=3$)



k-최근접 이웃을 통한 분류 예 ($k=3$): 1, 2단계

04 k-최근접 이웃을 통한 분류

- 3단계: 예측값 결정
 - k개의 데이터에서 가장 많이 등장한 이산형 실제값으로 예측



04 k-최근접 이웃을 통한 분류

- k-최근접 이웃 예제(분류)
 - 생도의 유전자 정보와 코로나 확진 여부가 주어졌다.
 - 신입 생도의 코로나 확진 여부를 k-최근접 이웃 문제를 통해 예측해보자.
(k=1, k=3)

유전자 정보에 따른 코로나 확진 여부 데이터(분류)

	유전자 1	유전자 2	유전자 3	유전자 4	확진 여부(y_i)
생도 A	2.54	4.33	3.99	2.57	정상
생도 B	3.12	3.87	3.84	3.04	정상
생도 C	2.76	4.17	5.63	3.28	정상
생도 D	3.87	3.56	4.25	3.65	확진
생도 E	3.55	3.91	2.68	4.22	확진
생도 F	4.12	2.86	3.30	3.71	확진
신입 생도	3.24	3.68	3.82	3.77	?

04 k-최근접 이웃을 통한 분류

- 생도 A~F와 신입생도의 유전자 정보를 통해 거리를 연산한다.
- 가장 가까운 데이터의 이산형 실제값을 통해 신입생도의 확진 여부를 결정한다. ($k=1$)

유전자 정보에 따른 코로나 확진 여부 데이터($k=1$)

	유전자 1	유전자 1	유전자 2	유전자 1	확진 여부	새 관측치와의 거리
생도 A	2.54	4.33	3.99	2.57	정상	1.54
생도 B	3.12	3.87	3.94	3.04	정상	0.76
생도 C	2.76	4.17	5.63	3.28	정상	2.00
생도 D	3.87	3.56	4.25	3.65	확진	0.78
생도 E	3.55	3.91	2.68	4.22	확진	1.28
생도 F	4.12	2.86	3.30	3.71	확진	1.31
신입 생도	3.24	3.68	3.82	3.77	정상	

04 k-최근접 이웃을 통한 분류


- 가장 가까운 3개의 데이터의 이산형 실제값을 통해 신입생도의 확진 여부를 결정한다. ($k=3$)

유전자 정보에 따른 코로나 확진 여부 데이터($k=3$)

	유전자 1	유전자 2	유전자 3	유전자 4	확진 여부	새 관측치와의 거리
생도 A	2.54	4.33	3.99	2.57	정상	1.54
생도 B	3.12	3.87	3.84	3.04	정상	0.76
생도 C	2.76	4.17	5.63	3.28	정상	2.00
생도 D	3.87	3.56	4.25	3.65	확진	0.78
생도 E	3.55	3.91	2.68	4.22	확진	1.28
생도 F	4.12	2.86	3.30	3.71	확진	1.31
신입 생도	3.24	3.68	3.82	3.77	확진	

05 k-최근접 이웃을 통한 회귀

- k-최근접 이웃 알고리즘 (회귀 문제)
 - y의 값이 이산형 데이터가 아닌 연속형 데이터일 경우에는 회귀를 수행
 - 알고리즘의 동작은 동일하나, k 개 데이터의 값의 평균을 회귀값으로 반환
 - 거리에 비례하여 가중치를 주는 방법도 존재



05 k-최근접 이웃을 통한 회귀

- k-최근접 이웃 예제 (회귀)
 - 생도의 과목별 최종 점수와 인공지능 입문 최종 점수 정보가 주어졌다.
 - 신입 생도의 인공지능 최종 점수를 k-최근접 이웃을 통해 예측해보자. (k=1, k=3)

타과목 점수에 따른 인공지능 입문 점수 데이터(회귀)

	미적분학	기초물리학	프로그래밍	통계의 이해	군사영어	인공지능 입문
생도 A	7.5	7.5	7.0	9.5	8.5	5.0
생도 B	7.5	7.0	7.5	8.0	8.0	6.0
생도 C	8.0	7.0	8.0	8.0	8.5	8.5
생도 D	8.5	8.0	9.5	7.5	6.0	7.0
생도 E	10.0	9.5	9.0	7.5	7.5	10.0
생도 F	9.0	9.0	8.0	8.0	8.0	9.0
신입 생도	9.0	8.5	8.0	7.0	8.0	?

05 k-최근접 이웃을 통한 회귀

타과목 점수에 따른 인공지능 입문 점수 데이터


	미적분학	기초물리학	프로그래밍	통계의 이해	군사영어	인공지능 입문	새 관측치와의 거리
생도 A	7.5	7.5	7.0	9.5	8.5	5.0	3.28
생도 B	7.5	7.0	7.5	8.0	8.0	6.0	2.40
생도 C	8.0	7.0	8.0	8.0	8.5	8.5	2.12
생도 D	8.5	8.0	9.5	7.5	6.0	7.0	2.65
생도 E	10.0	9.5	9.0	7.5	7.5	10.0	1.87
생도 F	9.0	9.0	8.0	8.0	8.0	9.0	1.12
신입 생도	9.0	8.5	8.0	7.0	8.0	?	

- k-최근접 이웃의 장점
 - 이상치에 대한 강건성 / 데이터의 분산 고려 / 많은 학습 데이터에 효과적
- k-최근접 이웃의 한계점
 - k 값 설정의 어려움 / 적절한 거리 측도 선택 / 계산 비용

o6 k-최근접 이웃의 하이퍼파라미터

- 하이퍼파라미터
 - 학습을 통해 탐색되지 않는 사용자 직접 결정 파라미터
 - 적절한 값 설정이 모델 성능에 큰 영향을 미침
- k 값의 역할
 - k는 가장 가까운 데이터의 개수로, 모델의 성능에 중요한 영향을 미침
- k 값 설정의 문제
 - 작은 k 값: 데이터의 지역적 특성을 과도하게 반영, 과대 적합 유발
 - 큰 k 값: 다른 범주의 개체 포함, 잘못 분류 위험, 과소 적합 유발
- 적절한 k 값 찾기
 - k 값을 변경하며 성능을 평가, 가장 좋은 성능을 보일 때의 k를 선택

o6 k-최근접 이웃의 하이퍼파라미터



k 값에 따른 분류 결과 예시

o8 코드로 구현하는 k-최근접 이웃

- 내용 : k-최근접 이웃 실습
- 실습 순서
 - 0 사용할 라이브러리와 패키지 불러오기
 - 1 (데이터) 데이터 불러오기 및 성분 추출하기
 - 2 (모델) 모델 구성하기
 - 3 (모델 학습) 모델 학습하기
 - 4 (모델 성능 평가) 모델 성능 평가하기
 - 5 (모델 성능 평가) 최적의 k 값 찾기
 - 6 (결과) 모델 동작 시각화하기

의사결정 트리

(DECISION TREE)


- 지도학습 측면에서의 의사결정 트리
- 의사결정 트리의 기본 개념
- 의사결정 트리 모델의 구조
- 의사결정 트리 모델의 동작 원리
- 의사결정 트리의 회귀 적용
- 코드로 구현하는 의사결정 트리

01 지도학습 측면에서의 의사결정 트리

- 타이타닉 생존자 예측(Titanic: Survivor Prediction)
 - 타이타닉 생존자를 예측을 위한 지도 학습 데이터
 - KNN 혹은 MLP 대신 의사결정나무를 사용해서도 분류가 가능하다.

타이타닉 생존자 예측 데이터(지도학습)

이름	나이(x_{i1})	동반 형제(x_{i2})	성별(x_{i3})	생존 여부(y_i)
인젤라	3	1	여성	생존
제임스	7	2	남성	생존
로날드	4	3	남성	사망
켈리	33	3	여성	생존
오스틴	35	0	남성	사망
앤써니	19	4	남성	사망
아니스	29	0	남성	사망
디카프리오	8	3	남성	?




| 타이타닉 생존 예측 의사결정 트리

02 의사결정 트리의 기본 개념

- 의사결정 트리

- 데이터에 존재하는 속성들을 나누는 일련의 규칙(질문)들을 학습을 통해 찾아 트리 형태로 표현하는 방법
 - 규칙은 프로그래밍의 'if-else'문의 표현과 유사
 - 트리는 일종의 분류 과정을 표현하는 것
 - 트리의 마지막 노드에는
분류 혹은 회귀의 예측결과가 나타남



의사결정 트리 예

02 의사결정 트리의 기본 개념

- 의사결정나무의 예
 - 아키네이터(Akinator) 게임 : 스무고개 놀이와 유사




아키네이터 게임(출처: <https://kr.akinator.com>)

03 의사결정 트리 모델의 구조

- 트리(Tree)의 구조
 - 노드(Node)
 - 뿌리노드(Root Node) : 시작되는 노드
 - 부모노드(Parent Node) : 주어진 노드의 상위 노드
 - 자식노드(Child Node) : 노드에서 분리된 하위 노드
 - 형제노드(Sibling Node) : 부모노드가 동일한 노드
 - 잎노드(Leaf Node) : 자식노드가 없는 노드
 - 엣지(Edge) : 노드와 노드를 연결하는 간선
 - 높이(Height) : 뿌리부터 잎노드까지의 깊이

03 의사결정 트리 모델의 구조




트리 구조의 예

04 의사결정 트리 모델의 동작 원리

- 분할 속성 및 정보 이득
 - 의사결정나무 분류 규칙
 - 의사결정나무의 노드 구성(분류 규칙 결정)이 가장 중요
 - 마지막 노드에 클래스나 예측값을 기입하고 상위 부모 노드들에는 if-else의 조건 기입
 - 분할 속성(Splitting attributes) : 부모 노드에 들어가는 if-else 조건들
 - 분할 속성을 잘 선택해야 연산적(비용적)으로 효율적인 의사결정나무를 만들 수 있음 (엔트로피 지수, 지니계수)

04 의사결정 트리 모델의 동작 원리



분할 속성 선택에 따른 의사결정 트리 구성 예

04 의사결정 트리 모델의 동작 원리

- 엔트로피: 사건이 일어날 확률을 통해 계산한 정보량(불확실성)을 의미함
 - 어떤 노드에서 분할 속성을 선택하였을 때 정보량을 계산하고, 해당 속성값의 엔트로피를 최소화하는 방향으로 의사결정나무 구조를 만드는데 활용됨
- 낮은 엔트로피 = 경우의 수가 적음 = 낮은 정보량 = 낮은 불확실성
- 높은 엔트로피 = 경우의 수가 많음 = 높은 정보량 = 높은 불확실성

$$h(D) = -\sum_{k=1}^m p_k \log p_k$$

- D : 데이터 집합
- m : 분류 문제에서 분류하고자 하는 실제값들의 가짓수
- p_k : k 번째 실제값에 해당하는 데이터의 확률. 엔트로피를 계산하려는 데이터 집합에서 k 번째 실제값에 해당하는 데이터의 비율로 계산한다.

04 의사결정 트리 모델의 동작 원리

- 엔트로피 예시
 - 사람의 나이, 수입, 학생 여부, 신용 등급 고려하여 컴퓨터의 구매 여부를 결정

컴퓨터 구매 여부 데이터

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주 좋음	구매
12	청년	중소득층	아니오	아주 좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주 좋음	미구매

04 의사결정 트리 모델의 동작 원리

- 전체 엔트로피의 연산
 - 컴퓨터를 구매할 확률 : $9/14$
 - 컴퓨터를 구매하지 않을 확률 : $5/14$

$$h(D) = \left(-\frac{9}{14} \log_2 \frac{9}{14} \right) + \left(-\frac{5}{14} \log_2 \frac{5}{14} \right) = 0.94$$

- 정보이득
 - 학습 데이터를 통해 각 노드의 분류 기준(속성)을 선정할 때, 각 속성의 효율성에 대한 측도
 - 각 노드별 정보이득을 최대화하는 특정 속성에 따라 데이터를 분류했을 경우, 가장 효율적인 분류 기준으로 구성된 트리 형태를 만들 수 있음.

04 의사결정 트리 모델의 동작 원리

- 각 속성을 기준으로 데이터를 분류했을 때의 엔트로피를 측정한다.
- 정보이득이 클수록 속성 A를 기준으로 데이터를 분류했을 때 얻을 수 있는 정보량이 많다.
- A를 기준으로 나눌 때 엔트로피가 작다면 해당 속성을 기준으로 데이터를 나누기 좋음 (분할 속성)
- 속성 A로 분류했을 때 A의 모든 클래스의 각 엔트로피를 계산한 후, 데이터의 개수만큼 가중치 부여

$$\text{Gain}(D, A) = h(D) - h_A(D)$$

$$h_A(D) = \sum_{v \in \text{Values}(A)} \frac{|D_v|}{|D|} \times h(D_v)$$

- $\text{Values}(A)$: 속성 A가 가질 수 있는 값의 집합
- D_v : 속성 A의 값이 v인 데이터의 집합
- $|D|$: 데이터 집합 D의 크기

04 의사결정 트리 모델의 동작 원리

- 정보 이득 기반 모델 생성 방법(의사결정 트리 성장)
 - ID₃ 알고리즘을 활용한 의사결정나무의 성장
 - 일반적으로 의사결정나무를 생성하는 방법을 성장이라고 부름
 - 각 노드에서 엔트로피가 최대로 감소하도록 하는 분할 속성을 결정하는 과정
 - ID₃(Iterative Dichotomiser 3) : 반복적으로(iteratively) 데이터를 나누는(divides) 알고리즘
 - 탐다운 방식으로 정보이득을 최대화하는 탐욕적(greedy) 방식의 최적화 알고리즘
 - 각 노드마다 반복적으로 계산된 정보이득을 기반으로 노드별 데이터 분류 기준(속성)을 정함

04 의사결정 트리 모델의 동작 원리

- 첫 번째 분할 속성 결정: 전체 데이터(D)
 - 나이 속성 기준의 정보 이득

정보 이득 연산 예시 데이터: 나이 속성

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주 좋음	구매
12	청년	중소득층	아니오	아주 좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주 좋음	미구매

04 의사결정 트리 모델의 동작 원리

- 나이 속성 기준의 정보 이득

$$\text{Gain}(D, \text{age}) = h(D) - h_{\text{age}}(D)$$

$$h_{\text{age}}(D) = \frac{5}{14} \times \left(-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5} \right) \quad \text{——— 청소년 엔트로피}$$

$$+ \frac{4}{14} \times \left(-\frac{4}{4} \log \frac{4}{4} \right) \quad \text{——— 청년 엔트로피}$$

$$+ \frac{5}{14} \times \left(-\frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5} \right) \quad \text{——— 중년 엔트로피}$$

$$= 0.693$$

$$\text{Gain}(D, \text{age}) = h(D) - h_{\text{age}}(D) = 0.94 - 0.693 = 0.247$$

04 의사결정 트리 모델의 동작 원리

- 수입 속성 기준의 정보 이득

정보 이득 연산 예시 데이터: 수입 속성

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주 좋음	구매
12	청년	중소득층	아니오	아주 좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주 좋음	미구매

04 의사결정 트리 모델의 동작 원리

- 수입 속성 기준의 정보 이득

$$\text{Gain}(D, \text{income}) = h(D) - h_{\text{income}}(D)$$

$$\begin{aligned} h_{\text{income}}(D) &= \frac{4}{14} \times \left(-\frac{2}{4} \log \frac{2}{4} - \frac{2}{4} \log \frac{2}{4} \right) \text{ ————— 고소득층 엔트로피} \\ &\quad + \frac{6}{14} \times \left(-\frac{4}{6} \log \frac{4}{6} - \frac{2}{6} \log \frac{2}{6} \right) \text{ ————— 중소득층 엔트로피} \\ &\quad + \frac{4}{14} \times \left(-\frac{3}{4} \log \frac{3}{4} - \frac{1}{4} \log \frac{1}{4} \right) \text{ ————— 저소득층 엔트로피} \\ &= 0.911 \end{aligned}$$

$$\text{Gain}(D, \text{income}) = h(D) - h_{\text{income}}(D) = 0.94 - 0.911 = 0.029$$

04 의사결정 트리 모델의 동작 원리

- 학생 속성 기준의 정보 이득

정보 이득 연산 예시 데이터: 학생 속성

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주 좋음	구매
12	청년	중소득층	아니오	아주 좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주 좋음	미구매

04 의사결정 트리 모델의 동작 원리

- 학생 속성 기준의 정보 이득

$$\text{Gain}(D, \text{student}) = h(D) - h_{\text{student}}(D)$$

$$\begin{aligned} h_{\text{student}}(D) &= \frac{7}{14} \times \left(-\frac{6}{7} \log \frac{6}{7} - \frac{1}{7} \log \frac{1}{7} \right) \text{ — 예 엔트로피} \\ &\quad + \frac{7}{14} \times \left(-\frac{3}{7} \log \frac{3}{7} - \frac{4}{7} \log \frac{4}{7} \right) \text{ — 아니오 엔트로피} \\ &= 0.789 \end{aligned}$$

$$\text{Gain}(D, \text{student}) = h(D) - h_{\text{student}}(D) = 0.94 - 0.789 = 0.151$$

04 의사결정 트리 모델의 동작 원리

- 신용 등급 속성 기준의 정보 이득

정보 이득 연산 예시 데이터: 신용 등급 속성

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주 좋음	구매
12	청년	중소득층	아니오	아주 좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주 좋음	미구매

04 의사결정 트리 모델의 동작 원리

- 시료 득극 소선 기주이 전보 이드

$$\text{Gain}(D, \text{credit}) = h(D) - h_{\text{credit}}(D)$$

$$\begin{aligned} h_{\text{credit}}(D) &= \frac{8}{14} \times \left(-\frac{6}{8} \log \frac{6}{8} - \frac{2}{8} \log \frac{2}{8} \right) \text{ ———— 좋음 엔트로피} \\ &\quad + \frac{6}{14} \times \left(-\frac{3}{6} \log \frac{3}{6} - \frac{3}{6} \log \frac{3}{6} \right) \text{ ———— 아주 좋음 엔트로피} \\ &= 0.892 \end{aligned}$$

$$\text{Gain}(D, \text{credit}) = h(D) - h_{\text{credit}}(D) = 0.94 - 0.892 = 0.048$$

- 정보 이득이 가장 큰 속성을 분할 속성으로 정하기


$$\text{Gain}(D, \text{age}) = h(D) - h_{\text{age}}(D) = 0.247$$

$$\text{Gain}(D, \text{income}) = h(D) - h_{\text{income}}(D) = 0.029$$

$$\text{Gain}(D, \text{student}) = h(D) - h_{\text{student}}(D) = 0.151$$

$$\text{Gain}(D, \text{credit}) = h(D) - h_{\text{credit}}(D) = 0.048$$

04 의사결정 트리 모델의 동작 원리



나이 기준 분할 속성으로 만든 의사결정 트리

04 의사결정 트리 모델의 동작 원리

- 두 번째 분할 속성 결정: 청소년에 해당되는 데이터(D_{youth})
 - 청소년과 중년 데이터에 대한 정보 이득을 연산
 - 청년의 경우 모두 컴퓨터를 구입한다는 데이터이므로 더 이상 데이터 분류 필요 X
 - 나이가 청소년으로 분류된 5개의 데이터에 대한 정보 이득

$$\text{Gain}(D_{youth}, \text{income}) = h(D_{youth}) - h_{\text{income}}(D_{youth}) = 0.971 - 0.4 = 0.571$$

$$\text{Gain}(D_{youth}, \text{student}) = h(D_{youth}) - h_{\text{student}}(D_{youth}) = 0.971 - 0 = 0.971$$

$$\text{Gain}(D_{youth}, \text{credit}) = h(D_{youth}) - h_{\text{credit}}(D_{youth}) = 0.971 - 0.951 = 0.02$$


- 세 번째 분할 속성 결정: 중년에 해당되는 데이터(D_{senior})
 - 나이가 중년으로 분류된 5개의 데이터에 대한 정보이득

$$\text{Gain}(D_{senior}, \text{income}) = h(D_{senior}) - h_{\text{income}}(D_{senior}) = 0.971 - 0.951 = 0.02$$

$$\text{Gain}(D_{senior}, \text{student}) = h(D_{senior}) - h_{\text{student}}(D_{senior}) = 0.971 - 0.951 = 0.02$$


$$\text{Gain}(D_{senior}, \text{credit}) = h(D_{senior}) - h_{\text{credit}}(D_{senior}) = 0.971 - 0 = 0.971$$

04 의사결정 트리 모델의 동작 원리



청소년 데이터 분할 속성 적용 의사결정 트리

04 의사결정 트리 모델의 동작 원리




번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
10	중년	중소득층	예	좋음	구매
14	중년	중소득층	아니오	아주 좋음	미구매

중년 데이터 분할 속성 적용 의사결정 트리

04 의사결정 트리 모델의 동작 원리

- 불순도

- 데이터 내에서 서로 다른 범주가 혼합된 정도를 나타내는 척도
- 예를 들어, 데이터가 한 색상으로만 이루어져 있으면 불순도가 낮고, 서로 다른 색상이 균등하게 섞여 있으면 불순도가 높음



불순도 예

04 의사결정 트리 모델의 동작 원리

- 지니계수

- 데이터의 불순도를 측정하는 지표로, 0에서 1 사이의 값을 가짐
- 지니계수가 0이면 데이터가 완벽하게 분류된 상태를 의미하며, 지니계수가 1이면 데이터가 고르게 혼합된 상태를 의미함. 지니계수가 낮을수록 불순도가 낮음

$$GINI(D) = 1 - \sum_j \{p(j)\}^2$$

- $p(j)$: 특정 노드에서 데이터(D)의 실제값이 j 일 확률

- CART 알고리즘

- 지니계수를 사용하여 노드를 이진 분할함. 각 분할에서 지니계수를 최소화하는 방향으로 트리를 성장시킴

04 의사결정 트리 모델의 동작 원리

컴퓨터 구매 여부 데이터

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매

- 첫 번째 분할 속성 결정

$$GINI(D_{\text{뿌리}}) = 1 - \left\{ \left(\frac{4}{7} \right)^2 + \left(\frac{3}{7} \right)^2 \right\} = 0.49$$

04 의사결정 트리 모델의 동작 원리

- 나이 속성 기준의 지니계수


$$GINI(D_{\text{청소년}}) = 1 - \left\{ \left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right\} = 0$$

$$GINI(D_{\text{청년, 중년}}) = 1 - \left\{ \left(\frac{4}{5} \right)^2 + \left(\frac{1}{5} \right)^2 \right\} = 0.32$$

$$\begin{aligned} \text{불순도 감소량} &= GINI(D_{\text{루터}}) - \left(\frac{N_{\text{청소년}}}{N_{\text{루터}}} \times GINI(D_{\text{청소년}}) + \frac{N_{\text{청년, 중년}}}{N_{\text{루터}}} \times GINI(D_{\text{청년, 중년}}) \right) \\ &= 0.49 - \left\{ \left(\frac{2}{7} \times 0 \right) + \left(\frac{5}{7} \times 0.32 \right) \right\} = 0.26 \end{aligned}$$

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매

나이 속성에 따른 컴퓨터 구매 여부 데이터: 청소년 / 청년 및 중년



04 의사결정 트리 모델의 동작 원리


$$GINI(D_{\text{청소년, 청년}}) = 1 - \left\{ \left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right\} = 0.5$$

$$GINI(D_{\text{중년}}) = 1 - \left\{ \left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right\} = 0.44$$

$$\begin{aligned} \text{불순도 감소량} &= GINI(D_{\text{루터}}) - \left(\frac{N_{\text{청소년, 청년}}}{N_{\text{루터}}} \times GINI(D_{\text{청소년, 청년}}) + \frac{N_{\text{중년}}}{N_{\text{루터}}} \times GINI(D_{\text{중년}}) \right) \\ &= 0.49 - \left\{ \left(\frac{4}{7} \times 0.5 \right) + \left(\frac{3}{7} \times 0.44 \right) \right\} = 0.02 \end{aligned}$$

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매

나이 속성에 따른 컴퓨터 구매 여부 데이터: 청소년 및 청년 / 중년



04 의사결정 트리 모델의 동작 원리

- 수입 속성 기준의 지니계수

$$GINI(D_{\text{고소득층}}) = 1 - \left\{ \left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right\} = 0.44$$

$$GINI(D_{\text{중,저소득층}}) = 1 - \left\{ \left(\frac{3}{4} \right)^2 + \left(\frac{1}{4} \right)^2 \right\} = 0.375$$

$$\begin{aligned} \text{불순도 감소량} &= GINI(D_{\text{루트}}) - \left(\frac{N_{\text{고소득층}}}{N_{\text{루트}}} \times GINI(D_{\text{고소득층}}) + \frac{N_{\text{중,저소득층}}}{N_{\text{루트}}} \times GINI(D_{\text{중,저소득층}}) \right) \\ &= 0.49 - \left\{ \left(\frac{3}{7} \times 0.44 \right) + \left(\frac{4}{7} \times 0.375 \right) \right\} = 0.087 \end{aligned}$$

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매




그림 8-12 수입 속성에 따른 컴퓨터 구매 여부 데이터: 고소득층 / 중소득층 및 저소득층


04 의사결정 트리 모델의 동작 원리

$$GINI(D_{\text{고,중소득층}}) = 1 - \left\{ \left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right\} = 0.5$$

$$GINI(D_{\text{저소득층}}) = 1 - \left\{ \left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right\} = 0.44$$

$$\begin{aligned} \text{불순도 감소량} &= GINI(D_{\text{루터}}) - \left(\frac{N_{\text{고,중소득층}}}{N_{\text{루터}}} \times GINI(D_{\text{고,중소득층}}) + \frac{N_{\text{저소득층}}}{N_{\text{루터}}} \times GINI(D_{\text{저소득층}}) \right) \\ &= 0.49 - \left\{ \left(\frac{4}{7} \times 0.5 \right) + \left(\frac{3}{7} \times 0.44 \right) \right\} = 0.02 \end{aligned}$$

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매



수입 속성에 따른 컴퓨터 구매 여부 데이터: 고소득층 및 중소득층/ 저소득층

04 의사결정 트리 모델의 동작 원리

- 학생 속성 기준의 지니계수


$$GINI(D_{\text{학생}}) = 1 - \left\{ \left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right\} = 0.5$$

$$GINI(D_{\text{학생 아님}}) = 1 - \left\{ \left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right\} = 0.44$$

$$\begin{aligned} \text{불순도 감소량} &= GINI(D_{\text{루터}}) - \left(\frac{N_{\text{학생}}}{N_{\text{루터}}} \times GINI(D_{\text{학생}}) + \frac{N_{\text{학생 아님}}}{N_{\text{루터}}} \times GINI(D_{\text{학생 아님}}) \right) \\ &= 0.49 - \left\{ \left(\frac{4}{7} \times 0.5 \right) + \left(\frac{3}{7} \times 0.44 \right) \right\} = 0.02 \end{aligned}$$

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매

학생 속성에 따른 컴퓨터 구매 여부 데이터



04 의사결정 트리 모델의 동작 원리

- 신용 등급 속성 기준의 지니계수


$$GINI(D_{\text{아주 좋음}}) = 1 - \left\{ \left(\frac{1}{3} \right)^2 + \left(\frac{2}{3} \right)^2 \right\} = 0.44$$

$$GINI(D_{\text{좋음}}) = 1 - \left\{ \left(\frac{3}{4} \right)^2 + \left(\frac{1}{4} \right)^2 \right\} = 0.375$$

$$\begin{aligned} \text{불순도 감소량} &= GINI(D_{\text{루터}}) - \left(\frac{N_{\text{아주 좋음}}}{N_{\text{루터}}} \times GINI(D_{\text{아주 좋음}}) + \frac{N_{\text{좋음}}}{N_{\text{루터}}} GINI(D_{\text{좋음}}) \right) \\ &= 0.49 - \left\{ \left(\frac{3}{7} \times 0.44 \right) + \left(\frac{4}{7} \times 0.375 \right) \right\} = 0.087 \end{aligned}$$


번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주 좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매

신용 등급 속성에 따른 컴퓨터 구매 여부 데이터



04 의사결정 트리 모델의 동작 원리

- 불순도(지니계수) 감소량이 가장 큰 속성을 분할 속성으로 정하기



- 두 번째 분할 속성 결정: 청년, 중년에 해당되는 데이터

$$GINI(D_{\text{청년, 중년}}) = 1 - \left\{ \left(\frac{4}{5} \right)^2 + \left(\frac{1}{5} \right)^2 \right\} = 0.32$$

04 의사결정 트리 모델의 동작 원리


- 나이 속성 기준의 지니계수

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매

$$GINI(D_{\text{청년}}) = 1 - \left\{ \left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right\} = 0$$

$$GINI(D_{\text{중년}}) = 1 - \left\{ \left(\frac{1}{3} \right)^2 + \left(\frac{2}{3} \right)^2 \right\} = 0.44$$

$$\begin{aligned} \text{불순도 감소량} &= GINI(D_{\text{부모}}) - \left(\frac{N_{\text{청년}}}{N_{\text{부모}}} \times GINI(D_{\text{청년}}) + \frac{N_{\text{중년}}}{N_{\text{부모}}} \times GINI(D_{\text{중년}}) \right) \\ &= 0.32 - \left\{ \left(\frac{2}{5} \times 0 \right) + \left(\frac{3}{5} \times 0.44 \right) \right\} = 0.056 \end{aligned}$$



나이 속성에 따른 컴퓨터 구매 여부 데이터

04 의사결정 트리 모델의 동작 원리

- 수입 속성 기준의 지니계수

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매

$$GINI(D_{\text{고소득층}}) = 1 - \left\{ \left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right\} = 0$$

$$GINI(D_{\text{중, 저소득층}}) = 1 - \left\{ \left(\frac{3}{4} \right)^2 + \left(\frac{1}{4} \right)^2 \right\} = 0.375$$

$$\begin{aligned}
 \text{불순도 감소량} &= GINI(D_{\text{부모}}) - \left(\frac{N_{\text{고소득층}}}{N_{\text{부모}}} \times GINI(D_{\text{고소득층}}) + \frac{N_{\text{중, 저소득층}}}{N_{\text{부모}}} \times GINI(D_{\text{중, 저소득층}}) \right) \\
 &= 0.32 - \left\{ \left(\frac{1}{5} \times 0 \right) + \left(\frac{4}{5} \times 0.375 \right) \right\} = 0.02
 \end{aligned}$$

04 의사결정 트리 모델의 동작 원리

- 수입 속성 기준의 지니계수

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매


$$GINI(D_{\text{고, 중소득층}}) = 1 - \left\{ \left(\frac{2}{2} \right)^2 + \left(\frac{0}{2} \right)^2 \right\} = 0$$

$$GINI(D_{\text{저소득층}}) = 1 - \left\{ \left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right\} = 0.44$$


$$\begin{aligned}
 \text{불순도 감소량} &= GINI(D_{\text{부모}}) - \left(\frac{N_{\text{고, 중소득층}}}{N_{\text{부모}}} \times GINI(D_{\text{고, 중소득층}}) + \frac{N_{\text{저소득층}}}{N_{\text{부모}}} \times GINI(D_{\text{저소득층}}) \right) \\
 &= 0.32 - \left\{ \left(\frac{2}{5} \times 0 \right) + \left(\frac{3}{5} \times 0.44 \right) \right\} = 0.056
 \end{aligned}$$

04 의사결정 트리 모델의 동작 원리

- 수입 속성 기준의 지니계수



수입 속성에 따른 컴퓨터 구매 여부 데이터: 고소득층/중소득층 및 저소득층




수입 속성에 따른 컴퓨터 구매 여부 데이터: 고소득층 및 중소득층/저소득층

04 의사결정 트리 모델의 동작 원리

- 학생 속성 기준의 지니계수

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매



$$GINI(D_{\text{학생}}) = 1 - \left\{ \left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right\} = 0.44$$

$$GINI(D_{\text{학생 아님}}) = 1 - \left\{ \left(\frac{2}{2} \right)^2 + \left(\frac{0}{2} \right)^2 \right\} = 0$$

$$\text{불순도 감소량} = GINI(D_{\text{부모}}) - \left(\frac{N_{\text{학생}}}{N_{\text{부모}}} \times GINI(D_{\text{학생}}) + \frac{N_{\text{학생 아님}}}{N_{\text{부모}}} \times GINI(D_{\text{학생 아님}}) \right)$$


$$= 0.32 - \left\{ \left(\frac{3}{5} \times 0.44 \right) + \left(\frac{2}{5} \times 0 \right) \right\} = 0.056$$

학생 속성에 따른 컴퓨터 구매 여부 데이터

04 의사결정 트리 모델의 동작 원리

- 신용 등급 속성 기준의 지니계수

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매



신용 등급 속성에 따른 컴퓨터 구매 여부 데이터


$$GINI(D_{\text{아주 좋음}}) = 1 - \left\{ \left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right\} = 0.5$$

$$GINI(D_{\text{ 좋음}}) = 1 - \left\{ \left(\frac{3}{3} \right)^2 + \left(\frac{0}{3} \right)^2 \right\} = 0$$

$$\begin{aligned}
 \text{불순도 감소량} &= GINI(D_{\text{부모}}) - \left(\frac{N_{\text{아주 좋음}}}{N_{\text{부모}}} \times GINI(D_{\text{아주 좋음}}) + \frac{N_{\text{ 좋음}}}{N_{\text{부모}}} \times GINI(D_{\text{ 좋음}}) \right) \\
 &= 0.32 - \left\{ \left(\frac{2}{5} \times 0.5 \right) + \left(\frac{3}{5} \times 0 \right) \right\} = 0.12
 \end{aligned}$$

04 의사결정 트리 모델의 동작 원리

- 불순도(지니계수) 감소량이 가장 큰 속성을 분할 속성으로 정하기



∴ 신용 등급 속성을 통한 노드 분할

- 세 번째 분할 속성 결정: 청년, 중년이면서 신용 등급이 아주 좋음에 해당되는 데이터

$$GINI(D_{\text{아주 좋음}}) = 1 - \left\{ \left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right\} = 0.5$$

04 의사결정 트리 모델의 동작 원리

나이 속성에 따른 컴퓨터 구매 여부 데이터

번호	나이(x_{i1})	수입(x_{i2})	학생 여부(x_{i3})	신용 등급(x_{i4})	구매 여부(y_i)
6	중년	저소득층	예	아주 좋음	미구매
7	청년	저소득층	예	아주 좋음	구매


$$GINI(D_{\text{중년}}) = 1 - \left\{ \left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right\} = 0$$

$$GINI(D_{\text{청년}}) = 1 - \left\{ \left(\frac{1}{1} \right)^2 + \left(\frac{0}{1} \right)^2 \right\} = 0$$

$$\begin{aligned} \text{불순도 감소량} &= GINI(D_{\text{부모}}) - \left(\frac{N_{\text{중년}}}{N_{\text{부모}}} \times GINI(D_{\text{중년}}) + \frac{N_{\text{청년}}}{N_{\text{부모}}} \times GINI(D_{\text{청년}}) \right) \\ &= 0.5 - \left\{ \left(\frac{1}{2} \times 0 \right) + \left(\frac{1}{2} \times 0 \right) \right\} = 0.5 \end{aligned}$$

04 의사결정 트리 모델의 동작 원리


- 지니계수를 통해 최종 생성된 의사결정 트리



지니계수를 통해 최종 생성된 의사결정 트리

05 의사결정 트리의 회귀 적용

- 회귀 데이터의 경우 리프노드가 연속형 예측값인 회귀 트리를 만들 수 있다.
- 아래 데이터를 회귀 트리로 만드는 과정을 Step1~ Step3에 따라 알아보도록 하자.



프로 야구 선수의 연봉 데이터

선수	연차	안타 수	연봉
1	2	80	52
2	3	40	23
3	4	20	20
4	6	65	30
5	5	30	26
6	8	85	38
7	11	25	25
8	12	60	60
9	13	75	50
10	13	30	35
11	15	90	60
12	15	60	40

05 의사결정 트리의 회귀 적용

$$Var_{\text{전체}} = \frac{\sum_{i=1}^{N_{\text{전체}}} (y_i - \bar{y})^2}{N_{\text{전체}}}$$

- $Var_{\text{전체}}$: 주어진 데이터셋 전체의 분산값
- $N_{\text{전체}}$: 주어진 데이터셋을 구성하는 데이터의 수
- $\bar{y}$: 실제값의 평균

$$\text{분산 감소량} = Var_{\text{전체}} - \left(\frac{\text{기준 이하 데이터 수}}{\text{전체 데이터 수}} \times Var_{\text{기준 이하}} + \frac{\text{기준 초과 데이터 수}}{\text{전체 데이터 수}} \times Var_{\text{기준 초과}} \right)$$

- $Var_{\text{기준 이하}}$: 속성의 선택한 기준값보다 작은 데이터들의 분산값
- $Var_{\text{기준 초과}}$: 속성의 선택한 기준값보다 큰 데이터들의 분산값

05 의사결정 트리의 회귀 적용

- 연차를 기준으로 한 분산 감소량 계산

$$\begin{aligned}\text{분산 감소량} &= Var_{\text{전체}} - \left(\frac{N_{\text{기준 이하}}}{N_{\text{전체}}} \times Var_{\text{기준 이하}} + \frac{N_{\text{기준 초과}}}{N_{\text{전체}}} \times Var_{\text{기준 초과}} \right) \\ &= 187.19 - \left(\frac{1}{12} \times 0 + \frac{11}{12} \times 185.4 \right) = 17.2\end{aligned}$$

안타 수에 따른 분산 감소량

	기준	분산(기준 이하)	분산(기준 초과)	분산 감소량
안타 수	20	0.0	171.1	30.28
	25	6.25	163.84	49.61
	30	29.25	162.84	49.61
	40	29.25	162.60	69.03
	60	166.20	113.6	42.09
	65	146.2	62.0	69.03
	75	160.66	82.66	46.02
	80	172.69	121.0	23.11
	85	157.28	0.0	43.0

05 의사결정 트리의 회귀 적용

- 안타 수를 기준으로 한 분산 감소량


$$\begin{aligned}\text{분산 감소량} &= Var_{\text{전체}} - \left(\frac{N_{40\text{개 이하}}}{N_{\text{전체}}} \times Var_{\text{안타 40개 이하}} + \frac{N_{40\text{개 초과}}}{N_{\text{전체}}} \times Var_{40\text{개 초과}} \right) \\ &= 187.19 - \left(\frac{5}{12} \times 29.25 + \frac{7}{12} \times 162.60 \right) = 69.03\end{aligned}$$

연차에 따른 분산 감소량

	기준	분산(기준 이하)	분산(기준 초과)	분산 감소량
연차	2	0.0	185.4	17.2
	3	210.2	182.4	0.1
	4	208.2	160.9	14.4
	5	162.2	151.7	32.0
	6	129.7	148.8	46.9
	8	116.6	166.7	45.6
	11	105.1	104.0	82.5
	12	186.7	92.21	32.0
	13	171.5	100.0	27.6

05 의사결정 트리의 회귀 적용

- 분산 감소량에 따른 첫 번째 분할 속성 및 분할 지점 선택







- 분산 감소량에 따른 두 번째 분할 지점 선택

연차가 11년 이하인 선수들에 대한 분산 감소량

기준		분산(기준 이하)	분산(기준 초과)	분산 감소량
연차 수 (연차 11년 이하)	20	0	100.9	18.62
	25	6.25	108.16	26.05
	30	6.88	116.18	35.75
	40	2.25	82.66	66.67
	65	10.95	49.0	83.27
	80	111.88	0.0	9.19

05 의사결정 트리의 회귀 적용



07 코드로 구현하는 의사결정 트리

- [1] scikit-learn 라이브러리를 이용한 의사결정 트리
- [2] 함수를 직접 정의해 구현한 의사결정 트리

- 내용 : 의사결정 트리 실습

- 실습 순서

- 0 사용할 라이브러리와 패키지 불러오기

- 1 (데이터) 데이터 불러오기

- 2 (데이터) 데이터 시각화 및 전처리하기

- 3 (모델) 의사결정 트리 모델 불러오기

- 4 (모델 학습) 알고리즘 수행하기

- 5 (모델 성능 평가) 테스트 데이터로 성능 평가하기

- 6 (결과) 모델 동작 시각화하기: scatter

- 7 (결과) 모델 동작 시각화하기: graphviz