







$$x = \mu + \sigma \cdot \epsilon$$



$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$$




Stable Diffusion 구성 요소

UNet

VAE(Encoder/Decoder)

Clip Text Encoder



Stable Diffusion 학습 데이터 세트

LAION (Large-scale Artificial Intelligence Open Network)

Stable Diffusion & LoRA(Low-Rank Adaptation of Large Models)





Figure 1: Our reparametrization. We only train A and B .



“We find that adding LoRA modules to just the **Query and Value** projections is sufficient.”

Transfer Learning vs LoRA

항목	LoRA	전통적 Fine-tuning (Transfer Learning)
가중치 수정	기존 weight 고정	기존 weight 수정
파라미터 수	매우 적음 (수천~수만)	큼 (수백만 이상)
기존 성능 유지	잘 유지됨	파괴 위험 있음
활용 대상	거대한 모델 일부만 학습	전체 또는 특정 모듈 학습

Stable Diffusion과 의료영상 생성 방법론

배경

- Stable Diffusion은 자연 이미지나 예술 그림에는 강하지만, 의료영상 특유의 패턴(CT, MRI, X-ray 등)은 학습된 적이 없거나 적음
- "MRI of a brain"같은 prompt를 넣으면 스타일만 비슷한 가짜 이미지가 생성될 확률 높음
- 진단에 쓰거나 학습 데이터로 쓸 수 있는 정확하고 구조적인 정보 부족

해결 전략

Step 1. LoRA로 의료영상 스타일만 미세 조정

- 기존 Stable Diffusion은 그대로 사용
- 의료영상 10~100장으로 LoRA 모듈 학습
- 학습 속도 빠르고, 기존 모델 보존하며, 적은 데이터로도 시작 가능
- 정확한 병변 위치, 병변간의 경계등을 제대로 이해하기 힘드므로 구조적 표현 한계 존재

Step 2. VAE 또는 Unet 전체를 Fine-tuning

- 원래 Latent space가 의료에 적합하지 않을 수 있으므로 VAE 수정 필요
- 전체 Unet 구조를 의료영상 기반으로 재학습
--> 데이터가 수천~수만 장 필요할 수 있음
- 의료영상에 적합한 latent space 생성 및 의료에 특화된 복잡한 구조적인 요소 반영 가능
- 평소 학습할 때 자주 발생하는 여러가지 요소들(overfitting)에 따른 위험성 및 기존 Stable Diffusion의 성능 상실 가능

Step 3. Text Encoder 조정

- CLIP이 입력한 Prompt를 이해하고, 그에 해당하는 맥락적 의미를 갖는 vector를 생성해야하지만 의료에 대한 텍스트 표현 학습이 부족할 수 있으므로, CLIP을 별도로 의료 텍스트-이미지로 재학습
- CLIP 또한 거대 모델이므로, 잘못 학습할 경우 기존 CLIP의 성능 붕괴 가능성
- 의학적인 표현이 적합한 이미지-텍스트 쌍이 있어야하는데 구하기 어려움