

머신러닝 기반 항성의 최종 진화 단계 예측 모델 연구

김소연¹, 김준화²¹건양대학교 의료인공지능학과²건양대학교 인공지능학과

I. 서론

항성 (별)은 막대한 양의 플라즈마가 중력에 의해 뭉쳐져 밝게 빛나는 납작한 회전 타원형의 천체 [1]이다. 즉, 핵융합 반응을 통해 스스로 빛을 내는 천체 [1]를 일컫는다. 핵의 에너지가 고갈되면 항성은 수축 혹은 팽창하게 되어 다음 단계로 진화하는데, 이때 항성의 질량에 따라 일생이 결정된다. 항성의 최종 형태를 확인하기엔 오랜 시간이 걸리기 때문에 AI를 통해 항성의 정보를 분석하여 일생을 추적하고 예측할 수 있는 모델이 필요하다.

본 연구에서는 항성의 최종 형태를 예측하기 위해 항성의 정보 중 학습에 사용될 정보를 수식 계산 후 항성의 스펙트럼 유형(분광형) [2]과 MKK (Morgan-Kenan-Kellman) [3]에 근거하여 현재 항성의 유형을 정의한다. 정의된 문자형 정보를 인코딩 후, 머신 러닝 모델 중 Decision Tree, Random Forest, XGBoost, Light GBM을 이용한 예측 모델을 제안한다. 각 모델의 성능을 향상시키기 위해 Optuna를 사용하여 하이퍼 파라미터를 최적화하였다. 이후, Optuna를 사용하여 하이퍼 파라미터를 최적화하기 전/후의 결과에 대한 성능 비교 연구를 진행하였다.

II. 본론

2.1 데이터 수집 및 전처리

항성 데이터는 학습 데이터 [4]와 테스트 데이터 [5] 데이터를 따로 수집하여 처리하였다. 학습 데이터에는 4개의 열 (겉보기 등급, 거리, 거리 오차범위, B-V색지수. 분광형)에 대한 데이터로 이루어졌으며, 테스트 데이터에는 6개의 열 (분광형, 온도(K), 항성 반지름, 각속도, B, V필터 파장)로 구성된 항성 정보 데이터이다. 수집한 데이터는 연구에 필요한 정보 (질량, 온도, 현재 형태, 최종형태)가 일부 없기 때문에 (1) ~ (5)의 공식을 통하여 데이터를 처리하였다.

2.1.1 학습 데이터 전처리

학습 데이터의 질량을 구하기 위해 적용한 수식은 (1)~(5)과 같다 [6].

$$1 \text{ mas} = 0.00099999995874704 [\text{arcsec}] \quad (1)$$

$$(1 \text{ pc} = 1 \text{ arsec(arcsecond)})$$

$$M = m + 5(\log_{10} p + 1) \quad (2)$$

$$B - V = -0.72 + \frac{7090}{T} \quad (3)$$

$$A = 4.8 - 2.5 \log \left(\frac{L}{L_{\text{sun}}} \right) \quad (4)$$

$$\frac{L}{L_{\text{sun}}} = \left(\frac{M}{M_{\text{sun}}} \right)^a \quad (5)$$

수식 (1)~(5)를 활용한 전처리 과정은 다음과 같이 진행된다. 첫 번째, 학습 데이터의 plx(거리)에 대한 열의 단위를 (1)을 사용하여 pc(천문 거리 단위)로 변환한다.

두 번째, 첫 번째에서 구한 pc를 (2)의 로그식에 대입하고, 학습 데이터의 m(겉보기 등급)을 대입하여 A(절대등급)를 구한다.

세 번째, (3)의 식을 T(온도)에 대한 식으로 정리 후 학습 데이터의 B-V(색지수)를 대입하여 T를 구한다.

네 번째, (4)의 공식을 각각 L(실제 광도), L_{sun} (상대 광도)에 대해 식을 정리 후, 두 번째의 A를 대입하여 L, L_{sun} 을 구한다.

마지막으로, (5) 관계식을 활용하여 항성의 M(질량)을 구한다.

위의 전처리 과정을 진행한 다음, 분광형과 MKK를 사용하여 현재 항성의 유형을 분류한다. 현재 항성 유형과 질량을 통해 항성의 최종 형태를 분류 후 항성 유형에 대한 모든 정보를 인코딩한다.

2.1.2 테스트 데이터 전처리

테스트 데이터의 전처리 과정은 2.1.1의 과정과 동일한 방식으로 진행되지만, (1)~(5)를 진행하기 위한 정보 (B-V 색지수, m(겉보기 등급), L(광도))의 부재로 이들을 구하기 위한 수식 (6) ~ (9) [7 - 10]를 추가하여 전처리를 진행하였다.

$$B - V = m_B - m_V \quad (6)$$

$$L = 4\pi R^2 \sigma T^4 \quad (7)$$

$$F = \frac{L}{4\pi d^2} \quad (8)$$

$$m = -2.5 \log_{10}(F) + C \quad (9)$$

F는 Flux, d는 지구에서 항성까지의 거리, C는 상수를 의미한다.

2.2 모델 학습

본 연구에서 사용한 모델은 Decision Tree, Random Forest, XGBoost, LightGBM이고 하이퍼 파라미터의 최적화를 위해 Optuna를 적용하여 항성의 최종 형태를 예측하였다. Trial을 100으로 설정하여 하이퍼 파라미터를 최적화하도록 하였다. 각 모델에 대한 하이퍼 파라미터는 다음 [표 1]과 [표 2]에서 보여준다.

표 1. 모델 하이퍼 파라미터

Model	Hyper-parameter
Decision Tree	splitter: best, max_depth: None, min_samples_split: 2, min_samples_leaf: 1, max_leaf_nodes: None, max_features: None, random_state: None
Random Forest	n_estimators: 100, max_depth: None, min_samples_split: 2, min_samples_leaf: 1, max_features: 1.0, max_leaf_nodes: None, random_state: None
XGBoost	n_estimators: 100, booster: gbtrees, max_depth: 6, grow_policy: depthwise, learning_rate: 0.1, random_state: None
LightGBM	boosting_type: gbdt, num_leaves: 31, n_estimators: 100, max_depth: 1, learning_rate: 0.1, min_split_gain: 0.0, random_state: None

표 2. Optuna 모델 하이퍼 파라미터

Model	Optuna Hyper-parameter
Decision Tree	splitter: random, max_depth: 20, min_samples_split: 9, min_samples_leaf: 8, max_leaf_nodes: 13, max_features: log2, random_state: None
Random Forest	n_estimators: 900, max_depth: 23, min_samples_split: 9, min_samples_leaf: 1, max_features: 10, max_leaf_nodes: log2, random_state: None
XGBoost	n_estimators: 100, booster: gbtrees, max_depth: 17, grow_policy: depthwise, learning_rate: 0.1, random_state: 42
LightGBM	boosting_type: dart, num_leaves: 26, n_estimators: 100, max_depth: 29, learning_rate: 0.1, min_split_gain: 0.36, random_state: None

III. 연구결과

[표 3]은 다양한 머신러닝 모델의 Default 하이퍼 파라미터 값과 Optuna를 적용한 성능을 비교한 결과를 보여준다. 각 머신러닝 모델에서 MSE, MAE, 그리고 RMSE 값이 Random Forest와 LightGBM에서는 감소하였으나, Decision Tree와 XGBoost에서는 오히려 증가한 것을 확인했다. 이는, Decision Tree와 XGBoost 모델에서 과도하게 학습데이터에 최적화된 오버피팅 현상이 발생한 것으로

보인다. 따라서, 손실값이 감소한 모델인 Random Forest와 LightGBM에 대해 R2-Score를 측정하여, Random Forest에선 0.9528, LightGBM에선 0.8627의 결과를 얻을 수 있었다.

표 3. Default & Optuna 성능

Model	MSE	MAE	RMSE	R2-Score
Decision Tree	11.7622	3.302	3.4296	-
Optuna	13.29	3.6334	3.6455	
Random Forest	12.0594	3.3521	3.4727	
Optuna	11.4894	3.2701	3.3896	0.9528
XGBoost	13.8975	3.6316	3.7279	
Optuna	14.3224	3.6886	3.7845	
LightGBM	11.6234	3.3250	3.4093	-
Optuna	9.7980	3.0192	3.1302	

IV. 결론

본 논문은 항성 데이터를 활용하여 항성의 최종 형태를 예측하는 모델을 만드는 연구를 진행하였다. 모델에 Optuna를 적용한 결과, 일부 모델에선 기존 모델의 성능보다 낮게 측정되었지만, 전반적으로 Optuna의 모델이 기존 모델의 성능보다 향상되었다. 특히, Light GBM의 손실값이 크게 감소한 것을 확인 할 수 있었다. 향후 연구에선, 항성 데이터와 신호 데이터를 통해 각 항성의 유형별 전파, 주파수 신호를 분석하여 각 신호의 특징과 항성의 구성 화학원소를 파악할 수 있는 연구를 진행할 예정이다.

ACKNOWLEDGMENTS

“본 연구는 2024년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업 지원을 받아 수행되었음”(2024-0-00047)

REFERENCES

- [1] 후타마세 도시후미, 2018. 『천문학 사전』,그린북, pp.16
- [2] Sullivan, E. (2023). Evaluation of Different Classification Methods for Classifying Stars Based on the Harvard Stellar Classification System (Master's thesis, Utica University). pp. 2
- [3] Universe, Physics And (14 June 2013). “The Yerkes spectral classification”. Physics and Universe. Retrieved 31 August 2022.
- [4] <https://www.kaggle.com/datasets/vinesmsuic/star-categorization-giants-and-dwarfs>
- [5] <https://exoplanetarchive.ipac.caltech.edu/>
- [6] <https://github.com/BrunaClo/Star-Classification>
- [7] Stell, J. (n.d.). Stellar properties: Magnitudes and fluxes. Astronomy Notes. Available at: <https://www.astronomynotes.com/starprop/s5.htm>
- [8] “Luminosity of Stars”. Australia Telescope National Facility. 12 July 2004. Archived from the original on 9 August 2014.
- [9] Andrea Gabrielli; F. Sylos Labini; Michael Joyce; Luciano Pietronero (2004-12-22). Statistical Physics for Cosmic Structures. Springer. p. 377.
- [10] George, R. (n.d.). Fluxes and magnitudes. Caltech, pp. 1-2