

U-Net 모델 기반 유방암 초음파 이미지 데이터 분류 및 객체 분할

우건희¹, 신방호¹, 김준화²¹건양대학교 의료인공지능학과²건양대학교 인공지능학과

I. 서론

의료 영상 분석은 질병 진단과 치료 계획 수립에 있어 중요한 역할을 한다. 특히, 유방암과 같은 치명적인 질병의 조기 발견은 생존율을 크게 높일 수 있으며, 이를 위해 초음파 이미지와 같은 비침습적 의료 영상의 분석이 필수적이다 [1]. 그러나, 유방암 진단 과정에서 발생하는 대규모 의료 이미지 데이터를 정확하고 효율적으로 처리하는 것은 여전히 도전 과제로 남아 있다.

최근 딥러닝 기술의 발전으로 인해 의료 영상 데이터를 분석하는 다양한 모델이 개발되고 있다 [2]. 그중 U-Net 모델 [3]은 객체 탐지 및 분류 작업에 주로 사용되는 모델로 알려져 있으며 의료 영상에서 병변을 분리하고 구체적으로 탐지하는 데 유용한 모델로 알려져 있다. 본 연구는 U-Net 모델을 활용하여 유방암 초음파 영상 데이터를 분석하고, 이를 통해 암 병변의 분류 및 탐지를 목표로 한다.

II. 본론

2.1 Data Augmentation for Breast Ultrasound Image




그림 1. 유방암 초음파 영상과 마스크 데이터
(a) Benign, (b) Malignant

본 논문에 사용한 Breast Ultrasound Images Dataset [4]은 [그림 1]과 같이 2개의 비정상 클래스(Benign, Malignant)와 정상 클래스로 총 3개의 클래스를 포함한다. 그림 1-(a)는 전이 능력이 없는 종양, Fig. 1-(b)는 세포의 성장이 빠르며 전이가 쉬운 악성 종양을 보여준다. 하지만, Breast Ultrasound Images Dataset는 [표 1]과 같이 클래스 별 데이

터 불균형이 존재한다. 인공지능 모델을 학습시킬 때, 클래스 별 데이터 개수의 불균형이 발생할 경우 편향이 발생할 수 있기 때문에, 데이터 증강 모델 GAN [5]을 사용해 데이터를 증가시켰다. 추가로, 클래스 별 Weighted Cross Entropy 적용해 데이터 불균형을 최소화하고자 했다.

표 1. Breast Ultrasound Image Dataset의 클래스별 이미지 개수

Class	Number of images
Benign	891
Malignant	421
Normal	266
Total	1578

2.2 U-Net model




그림 2. U-Net 모델 구조

U-Net 모델 구조는 총 5개의 다운샘플링(Downsampling)과 업샘플링(Upsampling) 층으로 구성된다. 다운샘플링 경로에서는 각 층이 두 개의 Conv2D, BatchNorm, ReLU로 구성되어 있으며, 각각의 출력은 MaxPooling을 통해 크기를 절반으로 줄인다.

업샘플링 경로에서는 업샘플링된 출력과 다운샘플링에서 저장된 특성 맵을 skip connection을 통해 결합한 후 다시 두

개의 Conv2D, BatchNorm, ReLUfh 처리하는 구조를 사용한다. 마지막 출력층은 Conv2D(1x1) 층으로 구성되어 있으며, Sigmoid 함수를 사용하여 최종 예측값을 산출한다.

III. 실험 결과

3.1 Hyper Parameter

모델 학습에 사용한 하이퍼 파라미터는 아래 표 2와 같다. Optimizer는 Adam, 초기 LR는 0.0001, Epoch는 120 (EarlyStopping,patience=30), Batch_Size는 8, Loss Function은 Dice_Loss를 사용했다.

표 2. Hyper Parameter

Optimizer	LR	Batch_Size	Loss_Function
U-net	0.0001	8	Dice_Loss

3.2 Generate Prediction On Test Data




그림 3. (a) Test image (b) Ground-Truth
(c) U-Net Prediction mask (d) U-Net++ Prediction mask

그림 3-(a)는 테스트 데이터로 제공된 실제 초음파 이미지이고, 그림 3-(b)는 객체의 실제 경계나 위치를 나타낸다. 그림 3-(c)는 U-Net 모델이 예측한 결과를 보여주며, 모델이 테스트 이미지에서 탐지한 영역을 나타낸다. 그림 3-(d)는 U-Net++ 모델이 예측한 결과를 보여준다.

표 3. U-net과 성능 비교

Model	Test Loss	Test IoU
U-net	0.8183	0.6043
U-net++	0.8172	0.5839

표 3에서 U-net과 같은 계열로 잘 알려진 모델인 U-net++ 과 성능을 비교했다. U-Net++는 기존 U-Net과 유사하지만 Encoder와 Decoder 사이의 Semantic Gap을 연결시켜준다는 점과 각 branch의 출력을 평균해서 최종 결과로 사용한다는 점에서 차이가 존재한다 [6].

평가지표는 Test Loss와 Test IoU를 사용했다. 여기서 IoU는 이미지 분할 성능을 평가하는 지표 중 하나로, 모델이 예측한 분할 영역과 실제 분할 영역이 얼마나 일치하는지를 나타내는 값이다. U-Net의 Test Loss는 0.8183, U-Net++의 Test Loss는 0.8172로 이는 U-Net++의 예측에서 더 나은 성능임을 보여준다. U-Net의 Test IoU는 0.6043, U-Net++의 Test IoU는 0.5839로 U-Net이 U-Net++ 대비 0.204의 IoU가 높은 것을 확인할 수 있다.

IV. 결론

본 연구에서는 U-Net과 U-Net++ 모델을 활용하여 유방암 초음파 이미지 데이터를 분류하고 객체를 분할하는 실험을 진행하였다. 실험 결과 U-Net 모델이 U-Net++에 비해 우수한 성능을 보였다.

추후 연구에서는 모델의 일반화 능력을 평가하기 위해 다양한 의료 데이터를 적용해보고 성능 개선을 위한 하이퍼파라미터 최적화 및 Ensemble 기법을 적용해 볼 예정이다.

ACKNOWLEDGMENTS

“본 연구는 2024년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업 지원을 받아 수행되었음”(2024-0-00047)

참고문헌

- [1] Park Ji-yong, “Creating Fluid Attended Inversion Recovery Images Synthetic from Multi-Echo Gradient-Recalled Echo Images Through Deep Neural Networks.” Graduate School of Yonsei University, Korea’s master’s thesis, 2019. Seoul
- [2] Chen, X., Wang, X., Zhang, K., Fung, K. M., Thai, T. C., Moore, K., ... & Qiu, Y. (2022). Recent advances and clinical applications of deep learning in medical image analysis. Medical image analysis, 79, 102444.
- [3] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. In Medical image computing and computer-assisted intervention- MICCAI 2015: 18th international conference, Munich, Germany, October 5–9, 2015, proceedings, part III 18 (pp. 234–241). Springer International Publishing.
- [4] <https://www.kaggle.com/datasets/aryashah2k/breast-ultrasound-images-dataset/data>
- [5] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. Advances in neural information processing systems, 27.
- [6] Micallef, N., Seychell, D., & Bajada, C. J. (2021). Exploring the u-net++ model for automatic brain tumor segmentation. IEEE Access, 9, 125523–125539.