

다항 특성 로지스틱 회귀를 이용한 당뇨병 예측 모델 연구

최승효¹, 김준화²¹건양대학교 의료인공지능학과²건양대학교 인공지능학과

I. 서론

당뇨병은 전 세계적으로 심각한 공중보건 문제로, 조기 진단과 예방이 필수적이다. [1] 최근 인공지능(AI)과 머신러닝(ML) 기술은 다양한 의료분야에서 활용되고 있으며, 그 중 로지스틱 회귀(Logistic Regression) [2]는 이진분류에서 널리 사용되는 통계적 모델로, 환자가 당뇨병에 걸릴 확률을 예측하는 데 유용하다.

하지만 기본적인 로지스틱 회귀는 선형 관계만을 학습할 수 있어 한계가 있다. 이를 극복하기 위해 다항 특성 로지스틱 회귀(Polynomial Features diabetes Logistic Regression) [3]를 사용하였다. 이 기법은 입력 변수를 다항식으로 변환해 더 복잡한 패턴을 학습할 수 있도록 한다.

본 연구에서는 다항 특성 로지스틱 회귀를 사용하여 당뇨병 예측의 정확도를 높이는 동시에, Flask [4]를 활용하여 사용자가 자신의 건강 정보를 입력하면 당뇨병 위험을 예측할 수 있는 웹페이지에서 확인할 수 있는 시스템을 구축하는 것을 목표로 한다.

II. 연구내용과 방법

2.1 데이터 수집 및 전처리

본 연구에 사용된 diabetes [5] 데이터는 768명의 환자를 대상으로 수집된 당뇨병 관련 임상 정보와 생리적 지표로 구성된 표 형식의 데이터이다. 각 환자에 대해 임신 횟수, 혈당 수치, 혈압, 피부 두께, 인슐린 수치, BMI, 당뇨병 유전력 지수, 나이와 같은 변수들이 포함되어 있으며, 이를 바탕으로 당뇨병 발병 여부가 기록되어있다.

데이터 전처리의 순서는 [그림 1]과 같다. 첫 번째로, 8가지 질문으로 구성된 설문 응답에 따라 점수를 부여하고, 이를 기반으로 환자의 포도당 수치를 예측하였다. 두 번째로, 일부 수치형 변수의 결측값을 평균값으로 대체하여 분석에 활용하였다. 세 번째로, StandardScaler를 사용하여 평균 0, 표준편차 1로 표준화하였다. 마지막으로, 데이터셋을 학습용과 테스트용으로 8:2 비율로 나누어 활용하였다.




그림 1. 데이터 전처리 파이프라인

2.2 모델 학습

당뇨병 예측을 위해 기본적인 Logistic Regression 모델을 학습하고, 성능을 비교하기 위해 두 가지 정규화 모델을 추가적으로 학습하였다. 정규화는 모델의 복잡도를 줄이고, 불필요한 변수의 영향을 최소화하여 모델의 일반화 성능을 높이는 역할을 한다. 본 연구에서는 Elastic Net [6] 기법, Polynomial Features Logistic Regression을 도입하였다.

Elastic Net은 L1과 L2 정규화의 장점을 결합하여 두 정규화의 비율을 조절할 수 있는 기법이다. 이는 변수 선택과 다중공선성 문제를 동시에 해결하며, 변수 개수가 많고 상관관계가 강할 때 모델 성능을 최적화 하는 데 유용하다. Polynomial Features Logistic Regression은 기본 Logistic Regression의 선형 한계를 극복하기 위해 다항식 형태로 변수를 확장하여 비선형 패턴을 학습할 수 있게 한다.

III. 연구 결과

성능 평가는 정확도(Accuracy)와 손실값(Loss)을 기준으로 진행되었으며, 각 모델의 결과는 [표 1]에 나타나있다.

[표 1]의 모든 모델의 정확도가 비슷한 수준이었으나, Polynomial Features Logistic Regression에서 81.81%로 가장 높은 정확도를 보인다. 또한 손실값은 0.4359%로 가장 측면에서도 가장 낮은 손실을 보였으며, 이는 데이터의 비선형적 관계를 잘 반영한 결과로 해석된다.

표 1. 성능비교표

	Logistic Regression	Elastic Net	Polynomial Features Logistic Regression
Accuracy	0.7987	0.7987	0.8181
Loss	0.4670	0.4671	0.4539

추가적으로 Polynomial Features Logistic Regression의 Precision-Recall Curve와 ROC-AUC Curve의 결과값은 각각 0.8095와 0.8446으로, 아래 [그림 2]와 [그림 3]를 통해 모델의 분류 성능을 시각적으로 확인할 수 있다.




그림 2. Precision-Recall Curve 그림 3. ROC-AUC Curve

본 연구에서 개발한 웹페이지는 Flask 프레임워크를 기반으로 구축되었으며, 사용자가 자신의 건강 정보를 입력하면 실시간으로 당뇨병 위험을 예측하는 기능을 제공한다. 포도당에 대한 정확한 수치는 의료 기기를 통해 측정해야하므로, [그림 4]와 같이 대략적인 포도당 수치를 추정하기 위한 기능을 바탕으로 결과를 [그림 5]와 같이 확인할 수 있다. [그림 5]에서 추정한 포도당 수치를 바탕으로

포도당 자가진단

자가진단 목적을 사용하셨다면 질문지 하단의 skip을 눌러주세요.

영소모다 목이 자주 마르는가?
☐ Yes ☒ No

영소모다 소변을 자주 보게 되시는가?
☐ Yes ☒ No

다리가 팔꿈치, 발, 손에 건조하고 거칠고 갈라지는 피부가 발생하십니까?
☐ Yes ☒ No

사물을 볼 때 초점을 맞추기 어려움?
☐ Yes ☒ No

영소모다 더 자주 피로감을 느끼는가?
☐ Yes ☒ No

라식술 하는가?
☐ Yes ☒ No

체중이 감소하는가?
☐ Yes ☒ No

소변에서 당분시원한 냄새가 나는가?
☒ Yes ☐ No

Submit

그림 4. 2p.자가진단 질문지

결과

귀하의 포도당 자가진단 결과는: 70

발달된 포도당 수치: 128.43

Submit

그림 5. 3p. 자가진단 결과

내 정보 입력

임신환수:

성명:

성별:

과부부:

연령(수):

비만도:

당뇨병합동기:

이 글의 목적은 당뇨병 진단을 위한 것입니다.
내 정보:

포도당 수치:

귀하의 건강 상태를 입력하십시오.
128.43

Submit

그림 6. 4p. 생체정보 입력

결과

당뇨병 위험: 28.43905048239772%

Go Home

그림 7. 5p. 확률 출력

로 [그림 6]에서 당뇨병에 걸릴 확률을 예측하기 위해 추가적인 본인의 생체 정보를 입력한다. 마지막으로, [그림 7]에서 보이는 것과 같이, 머신러닝 기반의 당뇨병에 걸릴 확률을 예측하여 위험도를 나타내준다.

IV. 결론

본 논문은 다항 특성 로지스틱 회귀를 통해 당뇨병 예측 정확도를 높이고, Flask로 사용자 친화적인 웹 페이지를 구축하였다. 실험 결과, 해당 모델은 약 0.8181의 정확도와 0.4539의 손실 값을 보여 비선형적 데이터를 효과적으로 처리했음을 확인하였다. 향후 연구는 모델의 성능 개선과 웹 페이지 기능 확장에 중점을 둘 예정이다.

ACKNOWLEDGMENTS

“본 연구는 2024년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업 지원을 받아 수행되었음”(2024-0-00047)

REFERENCES

- [1] Hong, Eun Gyoung. “Diabetes Management Status in a University Hospital.” Korean Diabetes Journal, vol. 33, no. 3, pp. 241-250, 2009.
- [2] Bagley, S. C., White, H., & Golomb, B. A. (2001). Logistic regression in the medical literature: Standards for use and reporting, with particular attention to one medical domain. Journal of clinical epidemiology, 54(10), 979-985.
- [3] Brownlee, J. (2022). How to use polynomial feature transforms for machine learning.
- [4] Lee, C.-S., Lim, D.-W., No, S.-H., Kim, J.-E., Yu, Y.-J., Kim, T.-H., Park, S. B., Yoon, K.-H., and Jeong, C.-W., “Web Application Implementation Using Flask Model Serving: Urinary Stone Artificial Intelligence Application,” Proceedings of the 2021 Spring Conference, vol. 28, no. 1, pp. 454-456, 2021.
- [5] Hyun, J. K., “Prediction of Diabetic Neuropathy Using Machine Learning Techniques,” Journal of Korean Diabetes, vol. 23, no. 4, pp. 238-244, 2022. DOI: 10.4093/jkd.2022.23.4.238.
- [6] Jeong, J.-W., Zhou, K., Oh, S.-K., and Ryu, B.-G., “Design and Application of RBFNN Classifier Using Elastic Net,” Proceedings of the Korean Institute of Electrical Engineers Conference, vol. 2021.7, pp. 1767-1768, 2021.