

사투리와 표준어 간의 원활한 소통 : 제주도와 강원도 방언의 표준어 변환 연구

엄다현¹ 이수현¹ 문채은¹ 최예나¹ 김준화²¹건양대학교 의료인공지능학과²건양대학교 인공지능학과

I. 서론

언어는 사회의 문화를 반영하며, 지역마다 독특한 변이가 나타난다. 한국은 각 지역에서 고유한 사투리를 사용해왔으며, 사투리는 그 지역의 성향을 파악하는 등 문화의 중요한 부분을 차지해왔다 [1]. 예를 들어 부산은 예로부터 뱃일을 하는 사람들이 많았기 때문에 드센 억양의 말투를 사용하게 되었다고 한다. 그래서 지금도 부산은 역동적인 이미지를 강조하며 지역의 색을 드러내고 있다. 그러나 표준어 중심의 언어 사용이 확산되면서 사투리 사용이 감소하고, 특히 사투리 변이가 심한 지역인 제주도는 화자의 의사소통이 제한되는 경우도 발생했다 [2]. 하지만 최근 몇 년간 음성 인식 및 자연어 처리 기술이 급속하게 발전하면서 자동 음성 번역 작업이 훨씬 더 효율적이고 정확해졌다 [3]. 이를 활용하여 본 연구는 활용한 사투리 데이터를 토대로 음성 인식 API와 머신러닝 알고리즘을 결합한 시스템을 개발하고자 한다. 이러한 시스템을 통해 사투리를 사용하는 화자가 자신의 지역적 언어를 사용하면서, 보다 넓은 범위의 사람들과 원활하게 의사소통할 수 있을 것으로 기대한다.

본 연구는 사투리와 표준어 간 언어적 차이를 분석하고, 변환 알고리즘을 설계하는 것을 목적으로 하며, 이를 통해 사투리 화자가 표준어 환경에서 원활히 소통할 수 있는 도구를 제공하고자 한다.

II. 연구내용과 방법

2.1 데이터 수집 및 처리 기법

본 연구에서는 AIHub 에서 제공하는 제주도와 강원도 방언 음성 데이터[4, 5]를 사용한다. AIHub는 한국 내 다양한 지역의 방언 음성 데이터를 제공하며, 제주도와 강원도 지역의 방언은 표준 한국어와 비교했을 때 언어적 차이가 크다는 점에서 연구 대상으로 선정되었다. 이 두 지역 방언은 독특한 어휘와 억양을 포함하고 있어, 이를 수집함으로써 연구의 신뢰성을 높일 수 있다.

활용된 음성 파일들은 10대에서 60대와 같은 다양한

연령대를 가진 참여자들로부터 확보한 데이터를 포함한다. 이를 통해 제주도와 강원도의 방언 특성을 최대한 반영할 수 있도록 한다.

본 연구에서는 도커(Docker) 기반의 환경을 구축하여 제주도와 강원도 방언을 대상으로 활용된 음성 데이터를 도커(Docker) 내에서 오픈소스 음성 인식 툴을 사용해 텍스트로 변환한다. 도커 환경에서 변환된 방언 텍스트는

후속 작업으로 GPT-4 [6] 모델을 통해 표준어로 변환한다. 이 과정은 방언의 고유한 특성을 반영하면서도 자연스럽게 표준어로 변환될 수 있도록 설계한다.

2.2 데이터 수집 및 처리 기법

2.2.1 GPT 기반 방언 텍스트의 표준어 변환




그림 1. 진행도 플로우 차트

본 연구에서는 방언 텍스트를 표준어로 변환하기 위해 GPT-4 모델을 활용한다. 데이터 출처는 AIHub에서 제공하는 제주도와 강원도 방언 음성 데이터로, 이를 텍스트로 변환한 후, 기존 연구에서 사용된 GPT-2 [4, 5] 모델을 바탕으로 방언을 표준어로 변환하는 방법론을 적용한다. 하지만 본 연구에서는 GPT-4를 사용하여 성능을 개선하고, 보다 자연스럽게 정확한 변환 결과를 얻고자 한다.

2.2.2 모델 설정

GPT-4는 이전 버전인 GPT-2에 비해 더 많은 파라미터와 고급 자연어 처리 기능을 갖추고 있어, 방언의 복잡한 패턴을 더 잘 이해하고 처리할 수 있다. 본 연구에서는

AIHub에서 수집한 방언 데이터를 바탕으로, 방언과 표준어 간의 관계를 명확히 반영하는 변환 모델을 구성한다.

2.2.3 전처리 과정

방언 텍스트를 GPT-4에 입력하기 전, 데이터 정제 및 전처리 과정을 통해 입력의 품질을 높인다. 방언 텍스트는 자연어 처리 과정에서 불필요한 기호나 오타자를 제거하고, 일관된 형식으로 정리한다. 이를 통해 모델이 방언의 맥락을 더욱 정확하게 이해할 수 있도록 한다.

2.2.4 변환 과정

GPT-4 모델은 입력된 방언 텍스트를 바탕으로 표준어 표현으로 변환하는 과정에서, 더 깊은 이해와 맥락 반영을 통해 자연스러운 결과를 생성한다. 이 과정에서 모델은 방언의 특성을 고려하면서도 표준어의 규범을 충족하는 변환을 수행한다.

2.2.5 모델 평가 및 개선

변환 결과는 다양한 평가 지표를 통해 검증되었으며, GPT-4의 성능 향상을 반영하여 정확성과 자연스러움을 지속적으로 개선하고자 한다. 또한, 사용자 피드백을 적극 반영하여 실제 사용 사례를 고려한 데이터 수집과 모델 재학습을 통해 변환 품질을 높이는 과정을 반복한다.

본 연구는 GPT-4 모델을 통해 방언 텍스트의 표준어 변환을 한층 개선함으로써, 사투리 화자들이 보다 원활하게 의사소통할 수 있도록 하는 데 기여하고자 하였다.




그림 2. GPT-2, GPT-4 성능 비교

자연어 처리(NLP)에서 모델이 생성한 텍스트의 품질을 평가하는 지표인 BLEU(Bilingual Evaluation Understudy)와, 언어 모델이 주어진 텍스트 시퀀스에서 얼마나 잘 다음 단어를 예측하는지 평가하는 지표인 Perplexity를 기준으로 GPT-2와 GPT-4의 성능을 비교한 것이다. Perplexity의 수치는 낮을수록 모델이 텍스트의 패턴을 더 잘 이해한다는 것을 의미한다.

III. 실험결과

음성파일을 도커를 사용하여 방언 텍스트로 변환 후 GPT-4를 활용하여 표준어로 결과를 도출하였다.

표 1. 표준어 변환 결과

방언	표준어
(경) (행) 양말도 (신겨꿔수다)	그렇게 해서 양말도 신겨줬어요.
아이고 (어평) (해서?)	아이고 어떻게 했어?
(어디넌) 확인하더라고 시간다 (돼가난)	어디냐고 확인하더라고 시간다 되어가니까.
아니 지금도 생각해도 (희여뜩히지예)	아니, 지금도 생각해도 무섭지요.
너무 많이 (먹언?)	너무 많이 먹었어?
(어떻해) (눈물남찌)	어떡해. 눈물 난다.

IV. 결론

본 연구는 제주도와 강원도 방언의 음성 데이터를 활용하여 사투리를 표준어로 변환했다. GPT-4 모델을 통해 방언의 특성을 잘 반영하면서도 자연스럽고 정확한 변환 결과를 얻었다. 이는 사투리 화자들이 표준어 환경에서도 원활히 의사소통할 수 있도록 도와줄 것으로 기대된다. 향후 연구에서는 데이터 다양성을 확장하고 사용자 피드백을 반영하여 모델 개선에 집중할 계획이다. 본 연구는 사투리의 가치와 지역 문화의 지속 가능성을 재조명하는 데 기여할 것이다.

ACKNOWLEDGMENTS

“본 연구는 2024년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업 지원을 받아 수행되었음”(2024-0-00047)

REFERENCES

- [1] 송종현, “지역방송의 사투리 사용 내용규제에 대한 연구”, 한국지역언론학회, 11권, 3호, 120-146, 2011.09.
- [2] <https://www.kookje.co.kr/news2011/asp/newsbody.asp?code=2500&key=20050211.22020214135>
- [3] <https://www.aitimes.kr/news/articleView.html?idxno=22445>
- [4] <https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=&topMenu=&aihubDataSe=data&dataSetSn=121>
- [5] <https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=&topMenu=&aihubDataSe=data&dataSetSn=118>
- [6] <https://github.com/AIGC-Audio/AudioGPT>